



ESCUELA TÉCNICA SUPERIOR DE INGENIERÍA DE
INFORMÁTICA

MÁSTER UNIVERSITARIO EN VISIÓN ARTIFICIAL

TRABAJO FIN DE MÁSTER

Conducción autónoma de un vehículo en un
simulador mediante aprendizaje extremo a
extremo basado en visión

Autor: Vanessa Fernández Martínez

Tutor: José María Cañas Plaza

Cotutor: Francisco Miguel Rivas Montero

Curso académico 2018/2019

Agradecimientos

Resumen

Índice general

Índice de figuras	V
Índice de tablas	VI
1. Introducción	2
1.1. Contexto y motivación	2
1.2. Visión artificial	4
1.3. Conducción autónoma	6
1.4. Redes neuronales artificiales	10
1.4.1. Redes neuronales convolucionales	11
1.4.2. Redes neuronales recurrentes	12
1.4.3. Tipos de capas	13
1.4.3.1. Capa Convolucional	13
1.4.3.2. Capa de <i>Pooling</i>	15
1.4.3.3. Capa <i>Fully connected</i>	15
1.4.3.4. Capa LSTM	16
2. Objetivos	17
2.1. Objetivos	17
2.2. Requisitos	18
2.3. Metodología	19
2.4. Plan de trabajo	21
3. Estado del arte	22
3.1. Bases de datos para conducción autónoma	22
3.1.1. Comma.ai	23
3.1.2. Udacity	23
3.1.3. SAIC Dataset	24
3.2. Simuladores	24
3.2.1. CARLA	25

3.2.2. Gazebo	26
3.2.3. Udacity's Self-Driving Car Simulator	27
3.2.4. Deepdrive 2.0	28
3.3. Redes neuronales	28
3.3.1. Redes neuronales convolucionales	29
3.3.2. Redes neuronales recurrentes	35
3.4. Infraestructura empleada	41
3.4.1. Simulador Gazebo	42
3.4.2. Entorno JdeRobot	43
3.4.3. Python	45
3.4.4. Biblioteca OpenCV	45
3.4.5. PyQt	47
3.4.6. Keras framework	48
3.4.6.1. Modelos	49
3.4.6.2. Capas	50
3.4.6.3. <i>Callbacks</i>	50
3.4.7. Formato de archivo HDF5	50
4. Infraestructura desarrollada	52
4.1. Circuitos	52
4.2. Piloto manual	52
4.3. Creación del dataset	52
4.4. Componente académico	52
5. Redes de clasificación	53
6. Redes de regresión	54
7. Conclusiones	55
Bibliografía	64

Índice de figuras

1.1.	Diagrama de Venn que muestra los campos que engloba la IA	3
1.2.	Navegación en robótica mediante VA	5
1.3.	Detección de cáncer de mama	5
1.4.	Detección de contenedores	6
1.5.	Conducción autónoma	6
1.6.	Comparación de neurona biológica (izquierda) y neurona artificial (derecha).	10
1.7.	Estructura de CNN	12
1.8.	Esquema de Redes Neuronales Recurrentes (RNN)	13
1.9.	Ejemplo de operación de convolución	14
1.10.	Ejemplo de capa <i>max pooling</i>	15
1.11.	Unidad LSTM	16
2.1.	Modelo en espiral	20
3.1.	Simulador CARLA	26
3.2.	Simulador Gazebo.	27
3.3.	Simulador Udacity's Self-Driving Car Simulator.	28
3.4.	Simulador Deepdrive.	29
3.5.	Arquitectura Pilotnet.	30
3.6.	Ejemplos de objetos salientes para varias imágenes de entrada.	32
3.7.	Arquitectura TinyPilotnet.	33
3.8.	Estructura de red ControlNet.	37
3.9.	Arquitectura C-LSTM.	38
3.10.	Arquitectura DeepestLSTM-TinyPilotnet.	41
3.11.	Simulador Gazebo.	42
3.12.	Ejemplo de componentes JdeRobot	44
3.13.	Funciones de OpenCV	46

Índice de tablas

Acrónimos

API Application Programming Interface.

CNN Redes Neuronales Convolucionales.

CSAIL MIT Computer Science & Artificial Intelligence Lab.

GUI Graphical User Interface.

HDF5 Hierarchical Data Format version 5.

IA Inteligencia Artificial.

ICE Internet Communications Engine.

LSTM Long Short-Term Memory.

RNA Redes Neuronales Artificiales.

RNN Redes Neuronales Recurrentes.

ROS Robot Operating System.

SDF Simulation Description Format.

SVG Scalable Vector Graphics.

VA Visión Artificial.

XML Extensible Markup Language.

Capítulo 1

Introducción

En este capítulo se definirá el contexto en el cual se sitúa este proyecto, y la motivación principal que ha llevado a su desarrollo. Se explicará de forma general qué es la visión artificial, así como el uso de redes neuronales en la misma. Además, se expondrá qué es la conducción autónoma.

1.1. Contexto y motivación

Desde la antigüedad el ser humano ha soñado con crear máquinas capaces de pensar. Cuando surgieron los primeros ordenadores programables, las personas se plantearon la idea de lograr que estos computadores adquirieran inteligencia, adquiriendo capacidades empleadas para realizar tareas propias de los humanos. Algunos ejemplos de estas tareas son entender el habla o las imágenes, y automatizar tareas rutinarias. El campo que desarrolla estas tareas se denomina Inteligencia Artificial (IA) [1] y cada vez tiene más presencia en temas de investigación.

En IA existen diversos desafíos muy interesantes; sin embargo, en la mayoría de ellos es extremadamente difícil alcanzar el rendimiento y la eficiencia del cerebro humano. Las máquinas nos superan en tareas como procesamiento de gran cantidad de datos, almacenamiento de información o tareas de razonamiento como el juego de ajedrez. Sin embargo, algunas habilidades que el ser humano realiza inconscientemente, como caminar o ver, son muy complejas para las máquinas; y por ello el cerebro humano supera a la máquina en este tipo de tareas.

CAPÍTULO 1. INTRODUCCIÓN

La IA comprende diferentes campos (Figura 1.1): *Machine Learning*, *Knowledge Engineering*, Lingüística computacional, Redes Neuronales Artificiales (RNA) [2], Procesamiento del lenguaje natural, Minería de datos, Visión Artificial (VA), etc. Este proyecto se enfoca en la VA, que trata de analizar y procesar imágenes de tal forma que un ordenador sea capaz de interpretar dichas imágenes. La IA intenta conseguir que una máquina realice el mismo proceso que el Sistema Visual Humano de tal forma que sea capaz de tomar decisiones y actuar en función de la situación en que se encuentre.

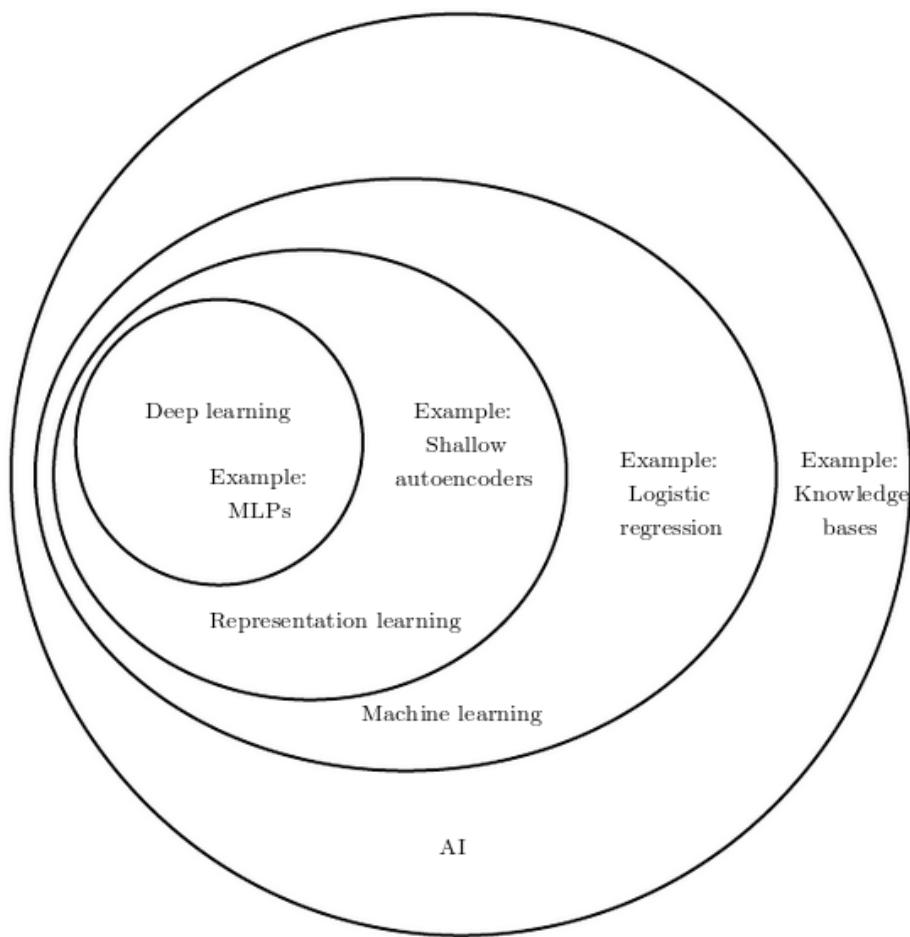


Figura 1.1: Diagrama de Venn que muestra los campos que engloba la IA

El aprendizaje de las máquinas es un punto de encuentro de diferentes disciplinas que engloba a la estadística, la geometría, la programación y la optimización, entre otras. La VA intenta simular las capacidades del ojo y el cerebro humano, empleando los conceptos de estas disciplinas.

Uno de los problemas que se está estudiando ampliamente en VA en la última década es la conducción autónoma. Los humanos somos capaces de mirar a la carretera y saber al instante si el coche que conducimos está en una curva o una recta, si hay coches alrededor y cómo interactúan entre ellos. En función a la situación en la que nos encontramos sabemos qué acciones llevar a cabo para lograr una buena conducción. Sin embargo, este procedimiento es más complicado para los ordenadores. En la actualidad se está investigando ampliamente cómo emplear las Redes Neuronales Artificiales (RNA) para predecir comportamiento autónomo en vehículos.

El objetivo principal de este proyecto es el estudio de conducción autónoma en simulación mediante Redes Neuronales Artificiales (RNA). En el estudio se incluyen diferentes arquitecturas de redes neuronales empleadas para imitar el comportamiento humano en un vehículo. Además, se presentarán los resultados de las distintas redes neuronales.

1.2. Visión artificial

Las primeras aplicaciones de la Visión Artificial datan de los años 60, donde destaca la creación del perceptrón, desarrollado por Frank Rosenblatt. Se considera la primera neurona artificial con capacidades de aprendizaje. Era capaz de distinguir figuras simples, como triángulos y cuadrados, a base de ensayo y error.

En la década de los 70 surgen las primeras aplicaciones comerciales de la VA, como por ejemplo el reconocimiento óptico de caracteres (OCR). Sin embargo, no es hasta los años 80 y 90 cuando la VA toma mayor peso. En la actualidad es una parte muy importante que contribuye a la transformación digital de diversos sectores. Por este motivo sólo es posible dar una pequeña pincelada sobre las múltiples aplicaciones en las que se ha aplicado hasta el momento.

Un claro ejemplo, es la navegación en robótica (Figura 1.2), donde la visión constituye una capacidad sensorial más para la percepción del entorno que rodea al robot. Generalmente se recurre a técnicas de visión estereoscópica con el fin de reconstruir la escena 3D. En algunas ocasiones se añade algún módulo de reconocimiento con el fin de identificar

CAPÍTULO 1. INTRODUCCIÓN

la presencia de determinados objetos, hacia los que debe dirigirse o evitar. Cualquier información que pueda extraerse mediante VA supone una gran ayuda para el movimiento del robot.



Figura 1.2: Navegación en robótica mediante VA

Otro ejemplo donde la VA supone un gran avance es en la comunidad médica, donde permite diagnosticar con mayor rapidez y detalle enfermedades y lesiones. De esta forma es posible aplicar tratamientos personalizados y eficaces en menor tiempo. Un claro ejemplo de investigadores que emplean VA es el MIT Computer Science & Artificial Intelligence Lab (CSAIL) [3], donde el desarrollo de algoritmos que analizan mamografías de una forma novedosa permite ayudar a detectar el cáncer de mama (Figura 1.3) con hasta cinco años de anticipación.

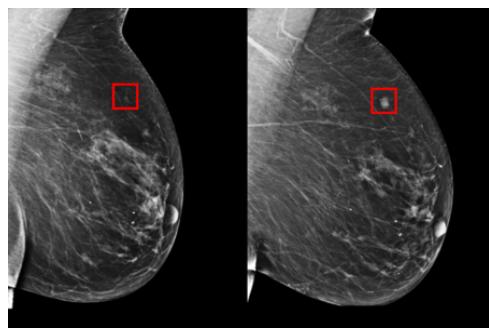


Figura 1.3: Detección de cáncer de mama

Una posible aplicación es el mantenimiento e inventariado urbano. Es posible identificar problemas en instalaciones y mobiliario urbano (averías, mal estado de

contenedores (Figura 1.4), socavones en la vía pública, etc) mediante cámaras ubicadas por ejemplo en autobuses. Los mantenimientos de infraestructuras de transporte, como vías y cables ferroviarios, pueden programarse automáticamente implantando sistemas de VA en los propios trenes.



Figura 1.4: Detección de contenedores

La reducción de accidentes gracias a vehículos autónomos es una realidad gracias a la VA, ya que los sistemas de guiado que poseen estos vehículos están basados en esta visión. Algunos ejemplos de estos sistemas (Figura 1.5) son: los sistemas de aviso de cambio de carril, o de control de velocidad de crucero.

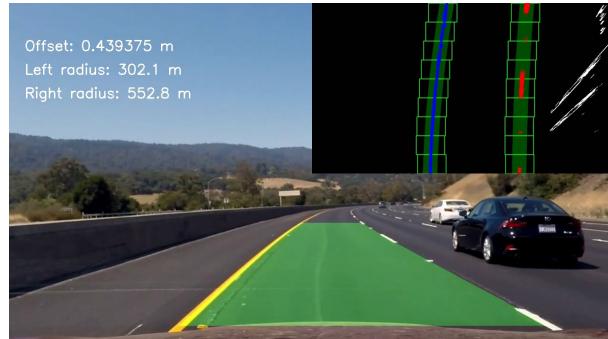


Figura 1.5: Conducción autónoma

1.3. Conducción autónoma

La conducción autónoma pretende que un vehículo sea capaz de conducir sólo en base a los datos proporcionados por determinados sensores (cámaras, LIDAR, etc), es decir, es capaz de aprender las normas de circulación. La posibilidad de crear un sistema capaz de conducir un vehículo ya se había contemplado en el siglo pasado. Sin embargo, la tecnología disponible en ese momento no permitía resolver una tarea tan compleja. Después

CAPÍTULO 1. INTRODUCCIÓN

de los avances tecnológicos cambió este hecho.

A finales del siglo pasado, algunos investigadores [4] [5] experimentaron con la creación de las primeras arquitecturas de conducción autónoma, desarrollando y probando algunos prototipos que podían conducir en calles reales. Estas pruebas se realizaron en áreas controladas y protegidas, y la conducción no fue lo suficientemente buena como para crear un producto de uso seguro. Estos experimentos dejaron claro que aún quedaba mucho para obtener una solución, pero al mismo tiempo, demostraron que la conducción autónoma podría convertirse en una perspectiva real.

En los últimos años se ha hecho mayor incapié en la investigación de la conducción autónoma con el fin de solventar el incremento de la tasa de muerte por accidentes de tráfico. Aunque algunos de estos accidentes se producen por fallos mecánicos del vehículo, la mayoría de dichos accidentes se debe a imprudencias y distracciones humanas. La conducción autónoma eliminaría estas distracciones haciendo posible la disminución de accidentes.

Hoy en día, cada vez existen más fabricantes de vehículos que incorporan tecnologías de conducción autónoma. Existe un estándar elaborado por la Sociedad de Ingenieros Automotrices (SAE), conocido como J3016 [6], que establece los niveles de conducción autónoma según la capacidad del vehículo.

- Nivel 0: No hay automatización de la conducción. Las tareas de conducción son realizadas en su totalidad por el conductor.
- Nivel 1: Asistencia al conductor. El vehículo posee algún sistema de automatización de la conducción (control de crucero, autoaparcamiento), ya sea para el control de movimiento longitudinal o el movimiento lateral, aunque no ambas cosas al mismo tiempo. El conductor realiza el resto de tareas de conducción, por lo que debe estar siempre atento.
- Nivel 2: Automatización parcial. Considera que el conductor ya no tiene que conducir en todo momento y que el coche empieza a ser realmente autónomo, aunque con ciertos matices. El vehículo es capaz de actuar de manera independiente dentro de

CAPÍTULO 1. INTRODUCCIÓN

escenarios controlados y en situaciones específicas de conducción. El conductor debe seguir prestada atención a lo que ocurre a su alrededor para evitar posibles riesgos. Un buen ejemplo de Nivel 2 de conducción autónoma pueden ser los modelos BMW Serie 7 o el Mercedes Clase E, capaces de moverse solos durante un tiempo o con el sistema de asistente de atascos.

- Nivel 3: Automatización condicional. En este nivel, el coche comienza a interactuar con el entorno que le rodea y es capaz de analizar posibles riesgos externos con el fin de evitarlos. Ya no se habla de conductor sino que hablamos de un usuario preparado para intervenir, es decir, el coche ya conduce completamente solo y el conductor es un simple vigilante de que todo funcione correctamente. El coche está preparado para ser conducido de manera habitual en cualquier momento.
- Nivel 4: Alta autonomía. En este nivel el sistema cuenta tanto con los sistemas de automatización presentes en el anterior nivel, como con sistemas de detección de objetos y eventos. Además, es capaz de responder ante ellos. El sistema de automatización de la conducción tiene un sistema de respaldo para actuar en caso de fallo del sistema principal y poder conducir hasta una situación de riesgo mínimo. En algunas situaciones es posible que el vehículo no siga conduciendo.
- Nivel 5: Autonomía total. Este nivel cuenta con todos los beneficios del sistema de automatización del nivel 4. Sin embargo, la diferencia es que en este caso el vehículo podría seguir conduciendo en todo momento o circunstancia.

Ejemplos importantes de conducción autónoma son: el DARPA Grand Challenge y el Urban Challenge. El DARPA Grand Challenge, organizado en 2004 y 2005 en Estados Unidos, fue una carrera de vehículos autónomos que debían recorrer 120 kms por el desierto de Nevada sin intervención humana y disponiendo únicamente de un listado de puntos intermedios entre el principio del circuito y el final. El Urban Challenge, organizado en 2007, fue una carrera de vehículos autónomos por zona urbana en la que debían recorrer 96 km en menos de 6 horas.

Como resultado de estos desafíos, destaca el proyecto ganador de 2005 de la Universidad de Stanford, cuyos miembros liderados por Sebastian Thrun acabaron desarrollando el vehículo autónomo de Google. En 2014, Google reveló un nuevo prototipo de su automóvil sin conductor (Firefly), que no tenía volante, pedal de acelerador o freno, siendo

CAPÍTULO 1. INTRODUCCIÓN

100 % autónomo, aunque era un prototipo empleado exclusivamente para pruebas. En la actualidad este vehículo se conoce como Waymo.

Este año, BMW y Mercedes-Benz han decidido unir fuerzas para desarrollar coches autónomos. Estas dos grandes compañías desarrollarán tecnologías para la creación de los próximos vehículos autónomos. Pretenden desarrollar ayudas a la conducción avanzadas y sistemas que automaticen la conducción en autopista y en el aparcamiento. Su objetivo es crear sistemas de conducción autónoma de nivel 4.

Tesla incluye el sistema inteligente Autopilot que alcanza el nivel de conducción 3. Sin embargo, Elon Musk ha anunciado este año que en 2020 será posible hablar de coches completamente autónomos (niveles 4 y 5), ya que su sistema Autopilot ofrecerá una conducción 100 % autónoma, donde el conductor pasaría a ser un mero espectador durante la conducción.

En la actualidad se están desarrollando sistemas que toman decisiones empleando una red neuronal profunda, la cual recibe información del entorno mediante diferentes sensores (LIDAR, radar, cámaras, etc.). A partir de los datos recogidos por los sensores la red predice unos valores de salida que serán los empleados para la conducción. Las decisiones tomadas por la red neuronal están determinadas por los datos empleados durante el entrenamiento de la red. Por lo tanto, cuanto más representativo sea el conjunto de datos, mejor rendimiento se espera que tenga la red, ya que conocerá todas las situaciones posibles en las que puede estar el vehículo.

Hoy en día el principal obstáculo para la conducción autónoma no se deriva de las limitaciones de la tecnología, sino de factores políticos, jurídicos, de regulación, de infraestructura y de responsabilidad que se deben abordar. A pesar de estas dificultades la investigación ha hecho muchos avances.

1.4. Redes neuronales artificiales

Una Red Neuronal Artificial RNA es un modelo matemático inspirado en el comportamiento biológico de las neuronas y en cómo se organizan dichas neuronas en el cerebro. Estas redes intentan imitar ciertas características propias de los seres humanos, como pueden ser la capacidad de memorizar y de asociar hechos. Estas neuronas siguen la misma estructura jerárquica que el cerebro humano, es decir, las diversas neuronas se organizan por capas.

Una comparativa entre las neuronas biológicas y las neuronas artificiales se puede observar en la Figura 1.6. Las neuronas biológicas constan de un cuerpo celular o soma que contiene un núcleo y ramas denominadas dendritas. Las dendritas transfieren la información de las células próximas mediante sinapsis al soma. Además, poseen un axón que lleva el impulso nervioso del soma a otras neuronas. Sin embargo, la neurona artificial es un modelo simplificado de las neuronas biológicas. Las sinapsis y las dendritas de la neurona artificial son las entradas al elemento procesador (soma). Cada una de estas entradas posee un peso asociado de conexión. Cada una de estas entradas es multiplicada por su peso y se suman generalmente estos productos, que pasan entonces a la función de la transferencia para generar un resultado que se transmita por la salida (axón).

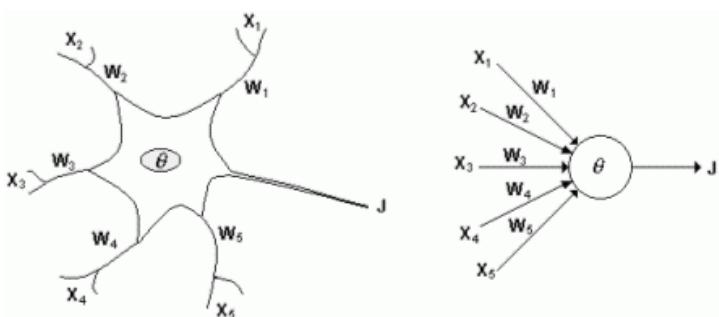


Figura 1.6: Comparación de neurona biológica (izquierda) y neurona artificial (derecha).

En este proyecto emplearemos la red multicapa, que consta de dos o más capas de neuronas interconectadas. Cada una de las capas puede hacer un tipo de transformación en su entrada, donde las señales atraviesan todas las capas. Cuando existen más de dos capas, hablamos de que la red posee capas ocultas. En esta red normalmente las capas iniciales

realizan generalizaciones simples, y en capas más profundas se hacen las generalizaciones más complejas.

La característica más especial del aprendizaje con redes neuronales es la capacidad de aprender y generalizar gracias a una base de datos específica para el problema que se debe tratar. Una vez esta red es entrenada, es capaz de estimar resultados para ejemplos que no ha visto anteriormente.

En este proyecto se emplearán dos tipos de redes neuronales para resolver el mismo problema. Por un lado se utilizan redes neuronales convolucionales y redes neuronales recurrentes.

1.4.1. Redes neuronales convolucionales

Las Redes Neuronales Convolucionales (CNN) son una clase de red neuronal artificial profunda que se emplean principalmente para clasificar imágenes, agrupar estas imágenes por similitud y realizar el reconocimiento de objetos dentro de las escenas. Este tipo de redes pueden identificar rostros, individuos, letreros de calles, tumores y muchos otros aspectos de los datos visuales.

Las CNN se basan en la arquitectura de la corteza visual del cerebro humano. Las CNN aplican una serie de filtros a los datos para extraer y aprender características de nivel superior, que el modelo puede usar para la clasificación, el reconocimiento u otro tipo de tarea. Las CNN están formadas por diferentes tipos de capas que veremos en las próximas subsecciones: capas convolucionales, capas de agrupación o *pooling*, y capas completamente conectadas o *fully connected*.

Las CNN siguen el esquema de la Figura 1.7 [7]. Normalmente este tipo de redes está formado por un conjunto de módulos convolucionales, que consisten en una capa convolucional seguida de una capa *pooling*. La capa convolución realiza una operación de convolución, mientras que la capa de agrupación o *pooling* genera características invariantes calculando estadísticas de las activaciones de convolución a partir de un campo receptivo (un pequeño campo de la capa anterior). En este tipo de redes, cada neurona de una capa oculta se conecta al campo receptivo local. En la capa convolucional, las

neuronas se distribuyen en diversas capas paralelas, denominadas mapas de características. En un mapa de características cada neurona está conectada a un campo receptivo local. Además, para cada mapa de características todas las neuronas comparten el mismo parámetro de peso conocido como *kernel* o filtro.

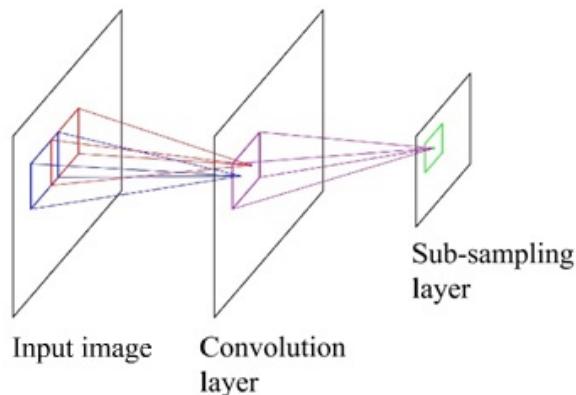


Figura 1.7: Estructura de CNN

Además, en este tipo de redes es importante tener en cuenta tanto las dimensiones de entrada como las dimensiones de las distintas capas. Las imágenes de entrada normalmente tienen dimensiones $W \times H \times C$, donde W es el ancho de la imagen, H es la altura, y C es el número de canales de la imagen. Cuando la información va atravesando las capas, normalmente se disminuye los valores $W \times H$, mientras que la profundidad de la red aumenta. Las primeras capas proporcionan una información localizada, es decir, el donde; mientras que las capas finales proporcionan información acerca del contenido de la imagen, es decir, el qué.

1.4.2. Redes neuronales recurrentes

Las Redes Neuronales Recurrentes (RNN) son un tipo de red neuronal artificial, donde la idea es usar información secuencial en vez de información independiente como en las redes tradicionales. En algunos casos emplear información independiente es mala idea, como puede ser en la predicción de la siguiente palabra en una cadena de texto, ya que sin información previa la red no es capaz de predecir la palabra.

Las RNN permiten que la información previa al instante actual persista. Una red neuronal recurrente se puede considerar como copias múltiples de la misma red, cada una de las cuales pasa un mensaje a su sucesor. En la Figura 1.8 se puede ver un esquema de RNN.

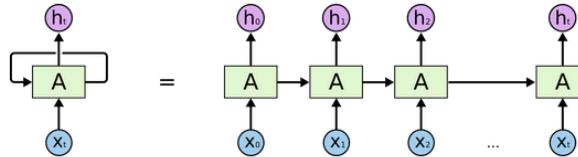


Figura 1.8: Esquema de Redes Neuronales Recurrentes (RNN)

Las Redes Neuronales Recurrentes (RNN) aprenden a emplear la información pasada en los casos donde la brecha entre la información relevante y la información actual es pequeña. Pero habrá casos donde necesitemos más contexto, como por ejemplo si queremos predecir la última palabra del texto “Crecí en Francia... Hablo francés con fluidez”. La información reciente sugiere que la siguiente palabra es un idioma, pero si queremos concretar qué idioma es, necesitamos el contexto desde más atrás. Sin embargo, a medida que aumenta la brecha, las RNN no son capaces de aprender a conectar la información. En cambio las LSTM no tienen ese problema.

Las redes Long Short-Term Memory (LSTM) [8] son un tipo especial de RNN capaz de aprender dependencias a largo plazo. Esta clase de redes fueron diseñadas para recordar información de períodos de tiempo largo. Se explicará más acerca de este tipo de red en las siguientes subsecciones.

1.4.3. Tipos de capas

En las siguientes subsecciones se explican los diferentes tipos de capas empleadas en las redes CNN y LSTM.

1.4.3.1. Capa Convolucional

Las capas convolucionales son las más importantes de una CNN. La operación de convolución (Figura 1.9) recibe como entrada una imagen y luego aplica sobre ella un filtro o

kernel que devuelve un mapa de características. Con esta operación se reduce el tamaño de los parámetros. En las capas convolucionales existen diferentes parámetros a tener en cuenta:

- Dimensiones de los filtros de convolución. Suelen ser una matriz cuadrada (tamaño $M \times M$). Cada píxel de cada mapa de características solamente tendrá en cuenta los píxeles que estén dentro del filtro.
- Número de filtros de convolución. Determina la profundidad del volumen de salida. Cada filtro genera un mapa de características.
- *Stride*. Determina cuánto vamos a deslizar el filtro sobre la matriz de entrada. Por ejemplo, cuando el stride es 1 se mueven los filtros 1 píxel a la vez.
- *Padding*. Añade alrededor de la matriz de entrada ceros para evitar perder dimensiones tras la convolución.

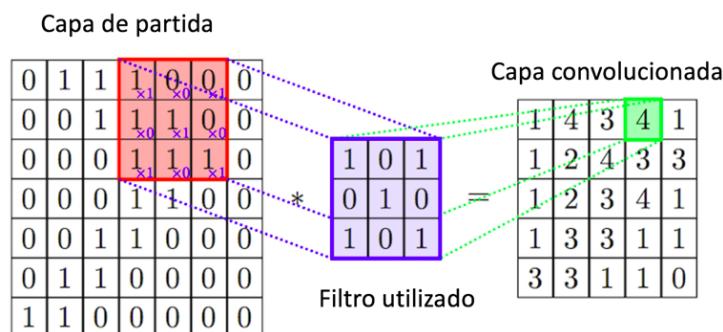


Figura 1.9: Ejemplo de operación de convolución

Se puede calcular el tamaño del volumen de salida en función al volumen de entrada (W), el tamaño del filtro de convolución (M), el stride aplicado (S) y la cantidad de zero-padding que se aplica (P). El tamaño del volumen de salida se calcula como: $(W - M + 2P) / (S+1)$.

Tras aplicar la convolución, se aplica una función de activación a los mapas de características. Esta función de activación es no lineal para conseguir modelos no lineales. La función de activación más usada es la función ReLU.

1.4.3.2. Capa de *Pooling*

La capa de *pooling* o de agrupación se coloca normalmente detrás de la capa convolucional. Se emplea para reducir las dimensiones espaciales (ancho x alto) del volumen de entrada, pero no afecta a la dimensión de profundidad del volumen.

En ocasiones la operación que realiza la capa de *pooling* se denomina reducción de muestreo debido a que la reducción de tamaño lleva a pérdidas de información. Aunque esta pérdida puede ser buena para la red por dos motivos: (1) trabaja en reducir el sobreajuste, (2) la disminución del tamaño produce un menor consumo de memoria durante el entrenamiento de las redes.

El funcionamiento de esta capa se basa en una ventana deslizante que actúa sobre el volumen de entrada. La operación realizada por esta ventana deslizante depende del tipo de *pooling* elegido. Las clases de submuestreo más empleadas son:

- *Max pooling*: Se queda con el valor máximo de los valores de la ventana deslizante. Se puede ver un ejemplo en la Figura 1.10
- *Average pooling*: Calcula cada píxel del volumen de salida realizando el promedio de los píxeles que se encuentran dentro de la ventana deslizante del volumen de entrada. Esta operación se hace canal por canal.

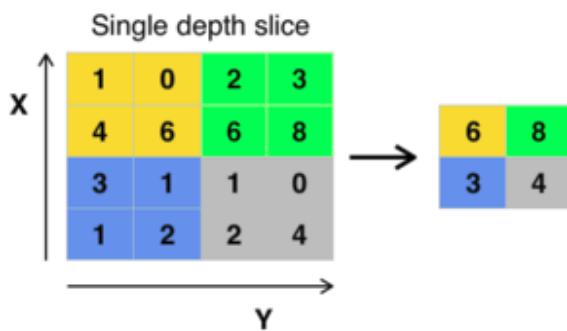


Figura 1.10: Ejemplo de capa *max pooling*

1.4.3.3. Capa *Fully connected*

Las capas completamente conectadas o *fully connected* conectan cada neurona de la capa de entrada con cada neurona de la capa de salida. Además, asignan un determinado

peso a cada conexión. La gran cantidad de conexiones produce que exista un gran número de parámetros configurables en esta capa.

1.4.3.4. Capa LSTM

La unidad LSTM puede añadir o quitar información, lo cual lo hace mediante estructuras denominadas puertas. Estas puertas son como una especie de camino para dejar pasar información. Una unidad LSTM tiene tres puertas.

- *Forget gate*. Decide qué información debe desechar.
- *Input gate*. Esta capa decide qué valores se deben actualizar.
- La unidad produce un *output* o valor de salida.

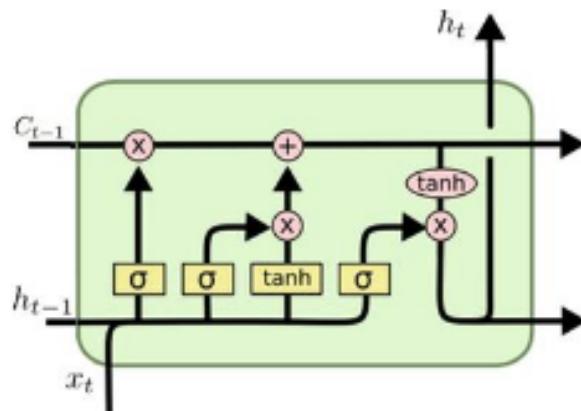


Figura 1.11: Unidad LSTM

Capítulo 2

Objetivos

Una vez explicado el contexto de este proyecto, se describirán en este capítulo los objetivos, los requisitos y la metodología empleados.

2.1. Objetivos

El propósito principal de este proyecto es el estudio de diferentes redes neuronales basadas en información visual que permitan a un vehículo ser capaz de conducir de forma autónoma.

El coche deberá ser capaz de conducir en diferentes circuitos en el Simulador Gazebo. Los entornos serán diferentes para que el vehículo sea capaz de aprender diferentes estímulos que le permitan conducir en situaciones complicadas.

Se creará un componente académico con la infraestructura necesaria que se comunica con el Simulador Gazebo, donde se podrá ver el resultado de la predicción de las redes neuronales. Para elaborar este componente se ha seguido la estructura de Robotics-Academy¹ y de dl-objectdetector². Este componente tendrá diferentes ingredientes:

- Infraestructura en el simulador.
- Nodo que permite cargar y emplear redes neuronales, además de incluir una GUI.

¹<https://jderobot.org/Robotics-Academy>

²<https://github.com/JdeRobot/dl-objectdetector>

- Fichero *MyAlgorithm.py* donde se proporciona al vehículo las órdenes de velocidad predichas por el nodo.

El objetivo principal es proporcionar una comparativa de diferentes modelos de redes neuronales que se pueden emplear para la conducción autónoma. Por este motivo, se estudiarán y se llevarán a cabo pruebas con diferentes arquitecturas de redes, como pueden ser redes neuronales convolucionales de clasificación y regresión o redes neuronales recurrentes de regresión.

2.2. Requisitos

El proyecto se desarrollará basándose en los subobjetivos mencionados anteriormente y tendrá que ajustarse a los requisitos de partida del proyecto. Estos requisitos condicionan la realización del proyecto, y son los siguientes:

1. La simulación se realizará en el simulador Gazebo, en concreto en la versión 7.15.0. El modelo de coche empleado es el modelo f1ROS (posee una cámara como sensor) creado por los desarrolladores de JdeRobot³. Este modelo se encuentra disponible en el repositorio de Github JdeRobot-assets⁴.
2. Se empleará el *middleware* robótico JdeRobot, en concreto en la versión 5.6.7. Este *middleware* se explicará en mayor detalle en el Capítulo 3. Esta plataforma simplifica el desarrollo del comportamiento del coche.
3. El sistema operativo que se empleará en este proyecto será Ubuntu 16.04.
4. El lenguaje de desarrollo empleado en los *plugins* del coche es C++. Sin embargo, en el resto de componentes se utilizarán el lenguaje Python. Debido a la compatibilidad con JdeRobot-5.6.7 y de éste con el *middleware* ROS Kinetic no se ha empleado Python-3.X, sino que se utiliza Python-2.7.
5. Se hará uso de la API de redes neuronales Keras, escrita en Python y capaz de ejecutarse sobre TensorFlow, CNTK o Theano. En este proyecto se ejecutará sobre TensorFlow y se empleará la versión 2.2.4.

³https://jderobot.org/Main_Page

⁴<https://github.com/JdeRobot/assets>

6. Las soluciones deben ser ágiles. Los algoritmos propuestos no pueden detenerse demasiado tiempo a pensar cuál será el próximo movimiento del vehículo, porque debe reaccionar rápido, en tiempo real y con movimientos suaves.

2.3. Metodología

El desarrollo del proyecto se ha realizado mediante una metodología iterativa, donde cada iteración está compuesta por varias fases: determinar objetivos, planificación, diseño e implementación, análisis de riesgos, además de reuniones periódicas con el tutor y el cotutor.

Se ha decidido seguir el modelo de desarrollo en espiral, creado por Barry Boehm [9] [10] [11]. Este modelo se adapta perfectamente a este tipo de proyectos, ya que permite separar el comportamiento final en varias subtareas más sencillas y después juntarlas. Además, el modelo permite una gran flexibilidad ante cambios en los requisitos, algo muy común en estos proyectos.

Este modelo de ciclo de vida permite obtener prototipos funcionales poco a poco, a la vez que se realiza el desarrollo del producto de forma incremental. El modelo consta de diferentes iteraciones, también conocidas como ciclos. En cada ciclo existen cuatro fases bien diferenciadas:

- Determinar objetivos: Se concretan los objetivos específicos que deben cumplirse para que el ciclo actual se considere terminado en función de los objetivos finales. Según se vayan incrementando las iteraciones, los objetivos serán más complejos.
- Análisis del riesgo: Se realiza un análisis detallado de cada posible riesgo que pueda tener el objetivo definido en la fase anterior. Se concretan los puntos a seguir con el fin de minimizar los riesgos, y después del análisis se planean estrategias alternativas.
- Desarrollar y probar: Se desarrolla el producto o las partes del producto que se han definido en las fases anteriores. Además, se realizan las pruebas necesarias que permitan asegurar la calidad de la implementación, y que pueda seguir funcionando en iteraciones futuras.

CAPÍTULO 2. OBJETIVOS

- Planificación: Se analizan los resultados obtenidos a través de las pruebas de la fase anterior, y es donde se planifica la siguiente iteración considerando los posibles errores que se han cometido.

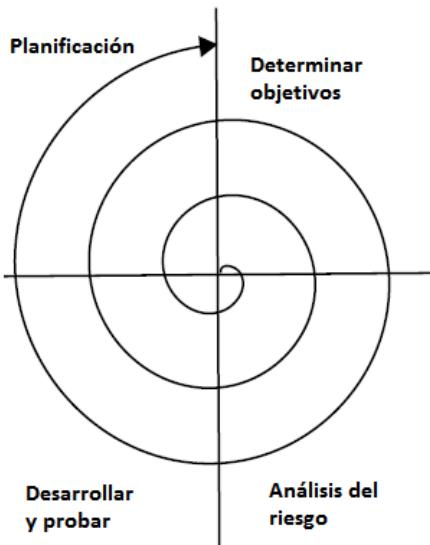


Figura 2.1: Modelo en espiral

Esta metodología se ha llevado a cabo mediante reuniones semanales con el tutor y el cotutor. En estas reuniones se analizaban los resultados de cada iteración, y en función de los resultados se fijaban nuevos objetivos. Además, en estas reuniones se analizaban los posibles fallos y se resolvían las dudas que iban surgiendo.

El código desarrollado semanalmente se ha subido al repositorio propio público de Github⁵, que emplea el sistema de control de versiones. Además, se ha desarrollado una bitácora en la página de JdeRobot⁶, donde semanalmente se han explicado los avances y se han mostrado los resultados mediante imágenes y vídeos.

El resultado del TFM, las diferentes redes neuronales desarrolladas, se encuentran disponibles en el repositorio Github, y se encuentran disponibles como software libre.

⁵<https://github.com/RoboticsURJC-students/2017-tfm-vanessa-fernandez>

⁶<https://jderobot.org/Vmartinezf-tfm>

2.4. Plan de trabajo

Las etapas en las que se divide el proyecto, que se corresponden con el modelo en espiral, son:

- Familiarización con la API de redes neuronales Keras y estudio de diferentes soluciones de aprendizaje extremo a extremo para conducción autónoma. En esta etapa se ha descargado e instalado Keras, así como todo el software necesario para desarrollar el proyecto. Además, se ha estudiado la creación de redes neuronales convolucionales en Keras, y su uso en algunos proyectos de la plataforma JdeRobot. Para tener una mejor comprensión de los diferentes modelos que se pueden emplear en conducción autónoma se han estudiado diferentes artículos.
- Desarrollo de la infraestructura necesaria en Gazebo, además de un componente académico que permita la conducción del coche, integrando una red entrenada en Keras en dicho componente.
- Creación de una base de datos que permita poder entrenar una red neuronal con la información visual del coche y los datos de velocidad.
- Estudio y mejora de redes neuronales convolucionales de clasificación aplicadas a la conducción autónoma. Se realizarán múltiples pruebas para tratar de conseguir la red más robusta posible y emplearla en el componente desarrollado.
- Estudio y mejora de redes neuronales convolucionales de regresión aplicadas a la conducción autónoma. Se realizarán diversas pruebas para intentar conseguir la red más robusta posible y emplearla en el componente desarrollado.
- Estudio y mejora de redes neuronales recurrentes de regresión aplicadas a la conducción autónoma. Se realizarán diversas pruebas para tratar de conseguir la red más robusta y emplearla en el componente desarrollado.

Capítulo 3

Estado del arte

En este capítulo se presenta el estado del arte sobre conducción autónoma mediante Redes Neuronales Convolucionales (CNN) y Redes Neuronales Recurrentes (RNN). Se describirán diferentes bases de datos para conducción autónoma como Comma.ai [12] o Udacity [13], así como diferentes arquitecturas de redes neuronales empleadas para el mismo problema como pueden ser *PilotNet* [14] o *ControlNet* [15]. Además, se describirán diferentes simuladores para conducción autónoma.

Además, se explican los diferentes ingredientes software en los que nos hemos apoyado para desarrollar el trabajo. Tales como el simulador Gazebo, el entorno JdeRobot, la librería OpenCV (empleada en el tratamiento de imagen), PyQt (para el desarrollo de la interfaz gráfica), Python como lenguaje de programación, Keras como framework para el desarrollo de redes neuronales, HDF5 como formato de archivo para guardar los modelos de redes neuronales.

3.1. Bases de datos para conducción autónoma

La conducción autónoma pretende que un vehículo sea capaz de conducir sólo en base a los datos proporcionados por determinados sensores. En concreto, la cámara es el sensor más empleado en las diferentes redes neuronales que se mencionarán en el estado del arte. Dado que queremos que el vehículo sea capaz de conducir bajo diferentes circunstancias, es decir, en diferentes entornos y diferentes iluminaciones, necesitaremos entrenar el modelo con un conjunto de imágenes representativo. Por ello, a lo largo de los últimos años han

surgido diferentes datasets con el fin de solucionar este problema. A continuación, se exponen algunos ejemplos de bases de datos empleadas para este propósito.

3.1.1. Comma.ai

La startup de conducción autónoma Comma.ai creó en 2016 un conjunto de datos [12] que permite probar modelos para controlar un vehículo autónomo. Este conjunto de datos consta de 11 videoclips grabados a 20 Hz por una cámara Point Grey colocada en el parabrisas de un Acura ILX 2016. El conjunto de datos es un archivo zip comprimido que ocupa un total de 45 GB.

Este conjunto de datos consta de un total de 7.25 horas de datos de conducción, donde los *frames* de vídeo tienen un tamaño de 160 x 320 píxeles. Junto a los archivos de video se proporciona un conjunto de medidas de sensores donde se registran medidas como la velocidad, la aceleración, el ángulo de giro, la ubicación del GPS y los ángulos del giroscopio.

Además registran los *time stamps* en los que se midieron estas medidas de los sensores y los *time stamps* en que se capturaron los *frames* de la cámara. Los datos los sensores se capturan en bruto y los *frames* de la cámara se almacenan en archivos HDF5 para que sean fáciles de usar en el aprendizaje automático y el software de control.

3.1.2. Udacity

Udacity posee un proyecto de código libre para conducción autónoma. El proyecto ofrece ejemplos de grabaciones de datos de más de diez horas de conducción y conjuntos de datos anotados de conducción, donde los objetos en el video han sido marcados con cuadros circundantes. Además de las herramientas de código abierto, Udacity publica desafíos de programación para promover el desarrollo del proyecto.

Inicialmente, Udacity [13] poseía 40 GB de datos públicos con el fin de facilitar a las personas la construcción de modelos competitivos sin acceso al tipo de datos de conducción que Tesla o Google poseen. Sin embargo, debido a que los modelos de aprendizaje profundo necesitan muchos datos, la compañía publicó 183 GB adicionales de datos de conducción.

El conjunto de datos de Ucadity [16] consta de 223 GB de datos. Estos datos fueron grabados durante más de 70 minutos de conducción en días soleados y nublados, repartidos en dos días en Mountain View. Las imágenes fueron grabadas por tres cámaras frontales: izquierda, derecha y central. La variedad de imágenes aumentará la calidad de los resultados y proporcionará a los participantes datos más realistas para poder trabajar, ya que este conjunto de datos representa mejor los desafíos de la conducción en el mundo real y las condiciones variables de la carretera. Los datos almacenados constan de latitud, longitud, marcha, freno, aceleración, ángulos de dirección y velocidad.

3.1.3. SAIC Dataset

En el artículo *End-to-end Multi-Modal Multi-Task Vehicle Control for Self-Driving Cars with Visual Perceptions* [17] se creó un nuevo conjunto de datos, llamado SAIC, con el fin de obtener un conjunto de datos para pruebas reales de conducción.

El conjunto de datos incluye cinco horas de datos de conducción en el área norte de San José, principalmente en carreteras urbanas. Este conjunto contiene datos de conducción tanto de día como de noche.

El vehículo es conducido entre varios puntos y cada viaje entre los puntos tiene una duración de aproximadamente diez minutos. El estacionamiento, la espera en el semáforo y otras condiciones se consideran partes ruidosas y se filtran. Después de filtrar los videos ruidosos, los datos de dos horas se dividen en entrenamiento, validación y conjunto de test.

En la grabación del conjunto de datos se incluyen tres conductores para evitar sesgos hacia un comportamiento de conducción específico. De manera similar, se graban flujos de video, valores de velocidad y direcciones. Las secuencias de video contienen videos de una cámara frontal central y dos laterales con una *frame rate* de 30 fotogramas por segundo.

3.2. Simuladores

Un vehículo es caro, lo que implica que muchas investigaciones sobre conducción autónoma solamente estén disponibles para centros de investigación y corporaciones.

Cuando se emplea un vehículo puede que algo falle al probarlo, pudiendo incluso romperse el vehículo. Hoy en día existen numerosos simuladores, lo que permite a cualquier persona crear, programar y probar infinidad de vehículos y escenarios de forma segura y económica. Algunos de los simuladores más empleados se explicarán a continuación.

3.2.1. CARLA

CARLA [18] [19] es un simulador de código abierto para la investigación de conducción autónoma. Se ha desarrollado desde cero para respaldar el desarrollo, el entrenamiento y la validación de sistemas de conducción autónomos. Además, admite diferentes conjuntos de sensores y condiciones ambientales.

CARLA (Figura 3.1) simula un mundo dinámico y proporciona una interfaz simple entre el mundo y un agente que interactúa con el mundo. Para llevar a cabo esta funcionalidad, CARLA está diseñado como un sistema cliente-servidor, donde el servidor ejecuta la simulación y renderiza la escena. La API del cliente se implementa en Python y es responsable de la interacción entre el agente autónomo y el servidor a través de sockets. El cliente envía comandos y metacomandos al servidor y recibe las lecturas del sensor. Los comandos (dirección, aceleración y frenado) controlan el vehículo. Los metamandatos controlan el comportamiento del servidor y se utilizan para restablecer la simulación, cambiar las propiedades del entorno (condiciones climáticas, iluminación y densidad de automóviles y peatones) y modificar el conjunto de sensores.

CARLA presenta las siguientes características:

- Escalabilidad a través de una arquitectura multi-cliente servidor: varios clientes en el mismo nodo o en diferentes nodos pueden controlar diferentes actores.
- Permite a los usuarios controlar todos los aspectos relacionados con la simulación (generación de tráfico, comportamientos de peatones, climas, sensores, etc).
- Los usuarios pueden configurar diversos conjuntos de sensores (LIDAR, cámaras, sensores de profundidad, GPS, etc).
- Permite deshabilitar la representación para ofrecer una ejecución rápida de la simulación del tráfico y los comportamientos de la carretera para los que no se



Figura 3.1: Simulador CARLA.

requieren gráficos.

- Se pueden crear mapas siguiendo el estándar OpenDrive a través de herramientas como RoadRunner.
- Los usuarios pueden definir diferentes situaciones de tráfico.
- Integra ROS.

3.2.2. Gazebo

Gazebo [20] (Figura 3.2) es un simulador 3D de código abierto distribuido bajo licencia Apache 2.0. Este simulador se ha utilizado en ámbitos de investigación en robótica e Inteligencia Artificial. Es capaz de simular robots, objetos y sensores en entornos complejos de interior y exterior. Posee gráficos de gran calidad y un robusto motor de físicas (masa del robot, rozamiento, inercia, amortiguamiento, etc.). Fue elegido para realizar el DARPA Robotics Challenge (2012-2015) y está mantenido por la Fundación Robótica de Código Abierto (OSRF).

Los modelos de robots que se emplean en la simulación son creados mediante algún programa de modelado 3D (Blender, Sketchup, etc). Estos robots simulados necesitan ser dotados de inteligencia para lo cual se emplean los plugins. Estos plugins pueden dotar al robot de inteligencia u ofrecer la información de sus sensores a aplicaciones externas y recibir de éstas comandos para los actuadores de los robots.



Figura 3.2: Simulador Gazebo.

3.2.3. Udacity's Self-Driving Car Simulator

Udacity's Self-Driving Car Simulator [13] [21] fue construido para Udacity's Self-Driving Car Nanodegree con el objetivo de que los estudiantes pudieran aprender cómo entrenar modelos de aprendizaje profundo que permitieran a los vehículos conducir de forma autónoma. Este simulador es de código abierto y requiere Unity.

El simulador de Udacity (Figura 3.3) permite al usuario seleccionar la escena deseada así como el modo de conducción en la pantalla principal. Existen dos modos de conducción: *Training Mode* y *Autonomus Mode*. En el modo *Training Mode* el coche se conduce manualmente mediante el teclado o el ratón y se almacenan los datos de conducción y las imágenes de las cámaras que posee el vehículo. Los datos grabados con este modo se pueden emplear para entrenar un modelo de aprendizaje automático. En el modo *Autonomous Mode* se puede probar el modelo de aprendizaje automático creado y comprobar su rendimiento en ejecución.

Técnicamente, el simulador actúa como un servidor desde el cual el programa puede conectarse y recibir un flujo de imágenes. Se puede crear un programa de Python que emplea un modelo de aprendizaje automático para procesar las imágenes de la carretera para predecir las mejores instrucciones de conducción y enviarlas de vuelta al servidor. Cada instrucción de conducción contiene un ángulo de dirección y un dato de aceleración, que cambia la dirección y la velocidad del automóvil.



Figura 3.3: Simulador Udacity’s Self-Driving Car Simulator.

3.2.4. Deepdrive 2.0

Deepdrive 2.0 [22] es un simulador de código abierto para Linux y Windows. Los simuladores actuales parecen vincularse a un hardware específico o no tienen forma de vincularse vehículos físicos. Deepdrive (Figura 3.4) para conseguir este propósito, incluye una amplia gama de sensores, automóviles y entornos y facilita la transferencia a vehículos reales. Esto permitirá que un mayor número de personas utilice únicamente el simulador para hacer pruebas constantes.

Presenta algunas características únicas respecto a otros simuladores de código abierto:

- El *frame rate* es más elevado al emplear varias cámaras, ya que emplea memoria compartida en lugar de sockets y transferencia asíncrona.
- La superficie de la carretera no es plana, sino que incluye colinas, curvas y la anchura de la carretera varía.
- El mapa, los automóviles, la iluminación, etc. son gratuitos y son modificables en Unreal.

3.3. Redes neuronales

La conducción autónoma no es posible sin un algoritmo que tome decisiones. En algunos casos estos algoritmos pueden ser redes neuronales. En esta sección se describirán



Figura 3.4: Simulador Deepdrive.

diferentes arquitecturas de redes neuronales empleadas en la conducción autónoma.

3.3.1. Redes neuronales convolucionales

El aprendizaje de extremo a extremo para conducción autónoma se ha explorado desde finales de los años ochenta. The Autonomous Land Vehicle in a Neural Network (ALVINN) [5] se desarrolló para aprender ángulos de dirección a partir de una cámara y las medidas proporcionadas por un láser mediante una red neuronal con una sola capa oculta. Basados en esta idea de redes de extremo a extremo (dada una imagen o imágenes se preciden ángulos de dirección), existen múltiples aproximaciones [23] [24] [25] de las cuales veremos algunas a continuación.

Un buen ejemplo de red de extremo a extremo es la red PilotNet [24] [14] creada por Nvidia. En [24] se describe dicha red con detalle. Es una red neuronal convolucional (CNN) que mapea píxeles en crudo de una sola cámara frontal a comandos de dirección directamente. El comando propuesto por la CNN se compara con el comando deseado para la imagen en concreto y los pesos de la red se van ajustando para aproximar la salida de la red a la salida deseada. El ajuste de los pesos se realiza empleando *back propagation*.

La red PilotNet (Figura 3.5) consta de 9 capas, que incluyen una capa de normalización, 5 capas convolucionales y 3 capas *fully-connected*. La imagen de entrada se divide en planos YUV y se pasa a la red. Las capas convolucionales las diseñaron para realizar la extracción de características y las eligieron a través de experimentos que variaban las configuraciones de capas. Las dos primeras capas convolucionales usaban un *stride* de 2x2

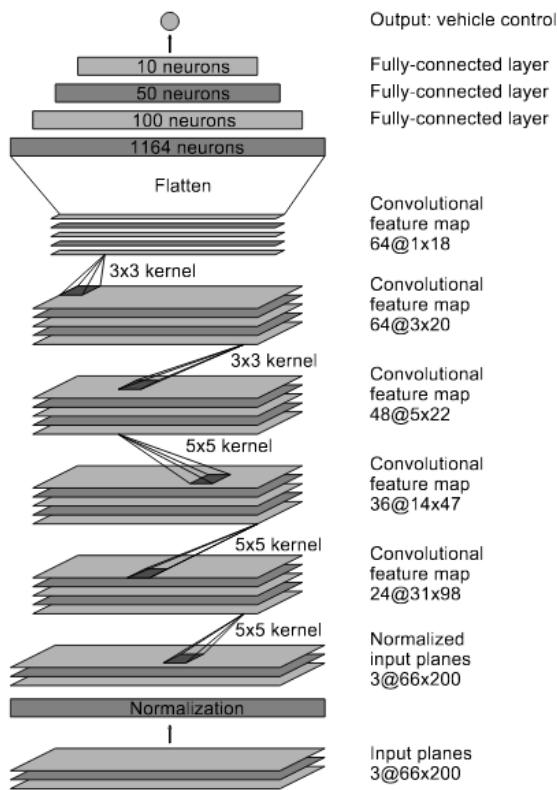


Figura 3.5: Arquitectura Pilotnet.

y un kernel 5x5, mientras que las 3 últimas capas usaban un *non-stride* y un kernel 3x3. Las 3 capas *fully-connected* fueron diseñadas para funcionar como un controlador de la dirección, pero no es posible saber exactamente qué partes de la red funcionan principalmente como extractor de características y cuáles sirven como controlador. El sistema aprende automáticamente las representaciones internas, como la detección de características útiles de la carretera.

El objetivo de [14] es explicar lo que PilotNet aprende y cómo toma sus decisiones. Con este fin, se desarrolla un método para determinar qué elementos en la imagen de la carretera influyen más en la decisión de la dirección de PilotNet. Llaman a estas secciones de imagen salientes los objetos salientes. Se puede encontrar un informe detallado del su método de detección de saliencia en [26].

La idea central de [14] para discernir los objetos salientes es encontrar partes de la imagen que corresponden a ubicaciones donde los mapas de características tienen las

mejores activaciones. Las activaciones de los mapas de nivel superior se convierten en máscaras para las activaciones de niveles inferiores utilizando el siguiente algoritmo:

1. En cada capa, las activaciones de los mapas de características se promedian.
2. El mapa con el promedio más alto se escala según el tamaño del mapa de la capa de abajo. El aumento de escala se realiza mediante una deconvolución. Los parámetros (*filter size* y *stride*) utilizados para la deconvolución son los mismos que se emplearon en la capa convolucional utilizada para generar el mapa. Los pesos de la deconvolución se establecen en 1.0 y los sesgos en 0.0.
3. El mapa promediado aumentado de un nivel superior se multiplica después con el mapa promediado de la capa de abajo (ahora son del mismo tamaño). El resultado es una máscara de tamaño intermedio.
4. La máscara intermedia se escala al tamaño de los mapas de la capa inferior de la misma manera que en el paso 2.
5. El mapa intermedio mejorado se multiplica de nuevo con el mapa promediado de la capa de abajo. Se obtiene una nueva máscara intermedia.
6. Los pasos 4 y 5 se repiten hasta que se alcanza la entrada. La última máscara que es del tamaño de la imagen de entrada se normaliza al rango 0-1 y se convierte en la máscara de visualización final.

Esta máscara de visualización muestra qué regiones de la imagen de entrada contribuyen más a la salida de la red. Estas regiones identifican los objetos salientes. En la Figura 3.6 se pueden ver ejemplos de objetos salientes para varias imágenes de entrada.

Los resultados muestran que PilotNet aprende a reconocer objetos relevantes en la carretera y que es capaz de mantener el vehículo en el carril con éxito en una amplia variedad de condiciones, independientemente de si las marcas del carril están presentes en la carretera o no.

En [27] se propone una nueva arquitectura de red, llamada TinyPilotnet, que se deriva de la red Pilotnet [24] [14]. La red TinyPilotnet (Figura 3.7) está compuesta por una capa de entrada, en la que se introducirán imágenes de resolución 16x32 y un único canal,



Figura 3.6: Ejemplos de objetos salientes para varias imágenes de entrada.

seguida por dos capas convolucionales de kernel 3x3, y una capa *dropout* configurada al 50 % de probabilidad para agilizar el entrenamiento. Finalmente, el tensor de información se convierte en un vector que es conectado a dos capas *fully-connected* que conducen a un par de neuronas, cada una de ellas dedicada a predecir los valores de dirección y aceleración respectivamente. La imagen de entrada tiene un solo canal formado por el canal de saturación del espacio de color HSV.

En [28] se presenta un enfoque de red neuronal profunda que emplea cámaras de eventos (sensores de inspiración biológica que no adquieren imágenes completas a una velocidad de *frames* fija, sino que tienen píxeles independientes que solo producen cambios de intensidad de forma asíncrona en el momento en el que ocurren) para predecir el ángulo de giro de un vehículo. Los eventos se convierten en *frames* de eventos por acumulación de píxeles en un intervalo de tiempo constante. Posteriormente, una red neuronal profunda los asigna a los ángulos de dirección.

En este artículo inicialmente apilan los *frames* de eventos de diferente polaridad, creando una imagen de eventos 2D. Después, implementan una serie de arquitecturas ResNet, es decir, ResNet18 y ResNet50. Estas redes son utilizadas como extractores de características para el problema de regresión, considerando solo las capas convolucionales. Para codificar

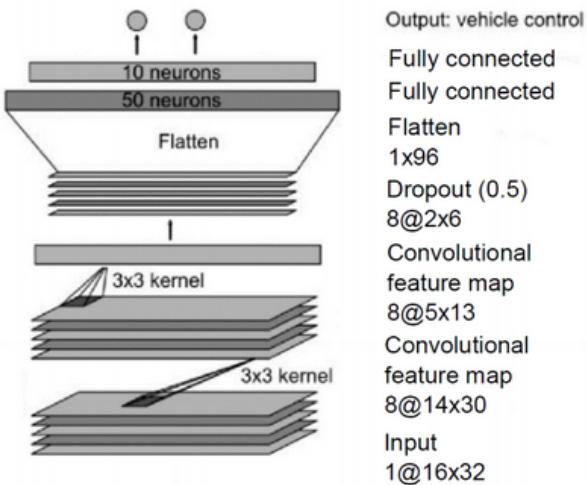


Figura 3.7: Arquitectura TinyPilotnet.

las características de la imagen extraídas de la última capa convolucional en un descriptor vectorizado, se emplea una capa *global average pooling* que devuelve la media del canal de las características. Después se agrega una capa *fully-connected* (con dimensionalidad 256 para ResNet18 y 1024 para ResNet50), seguida de una ReLU no lineal y una capa *fully-connected* unidimensional para generar el ángulo.

En [28] preciden ángulos empleando 3 tipos de entradas: 1. imágenes en escala de grises, 2. diferencia de imágenes en escala de grises, 3. imágenes creadas por la acumulación de eventos. Analizan el rendimiento de la red en función del tiempo de integración utilizado para generar las imágenes de eventos (10, 25, 50, 100 y 200 ms). Cuanto mayor es el tiempo de integración, mayor es la traza de eventos que aparecen en los contornos de los objetos. La red funciona mejor cuando se entrena con imágenes de eventos correspondientes a 50 ms, y el rendimiento se degrada para tiempos de integración cada vez más grandes. Uno de los problemas que presentan las entradas que emplean imágenes en escala de grises es que a altas velocidades las imágenes se difuminan y la diferencia de imágenes se vuelve muy ruidosa.

En [29] se realiza un amplio estudio donde se analiza una red neuronal de extremo a extremo para predecir las acciones de dirección de un vehículo en base a las imágenes de una cámara, así como las dependencias temporales de entradas consecutivas y la diferen-

cia entre redes de clasificación y redes de regresión.

La arquitectura principal que emplean es una variación de la arquitectura PilotNet, AlexNet o VGG19. Para AlexNet se elimina el *dropout* de las 2 capas densas finales y se reduce el tamaño de 500 y 200 neuronas. La capa de salida de la red depende de su tipo (regresión o clasificación) y para una red de clasificación del número de clases. Para el caso de clasificación, cuantifican las medidas del ángulo de dirección en valores discretos, que representan las etiquetas de la clase. Esta cuantificación es necesaria como entrada cuando se tiene una red de clasificación y permite equilibrar los datos a través de los pesos de la muestra. Esta ponderación actúa como un coeficiente para la tasa de aprendizaje de la red para cada muestra. El peso de una muestra está directamente relacionado con la clase a la que pertenece cuando se cuantifica. La ponderación de muestra se realiza para regresión y clasificación.

Se estudia la influencia de las especificaciones de cuantización de clase en el rendimiento del sistema. Estas especificaciones consisten en la cantidad de clases y la asignación del rango de entrada de estas clases. Se comparan redes con diferentes grados de granularidad, lo que influye en el rendimiento. Se compara un esquema de cuantificación de grano grueso de 7 clases con uno de grano fino de 17 clases, obteniendo mejores resultados con el de grano grueso.

Además, en este artículo se evalúan métodos que permiten que nuestro sistema aproveche la información de entradas consecutivas: un método que sigue una arquitectura de extremo a extremo y un método que emplea capas recurrentes (lo veremos en la siguiente subsección).

El método que emplea una CNN para la predicción, que llaman *stacked frames*, concatena varias imágenes de entrada consecutivas para crear una imagen apilada. La entrada a la red es esta imagen apilada (para la imagen t se concatenan las imágenes $t-1, t-2, \dots$). El tamaño de entrada será la única variable que se modifique, es decir, no se modifica la red. Por esta razón, las imágenes se concatenan en la dimensión de profundidad (canal) y no en una nueva dimensión. Por ejemplo, apilar 2 imágenes anteriores a la imagen RGB actual de $160 \times 320 \times 3$ cambiaría su tamaño a $160 \times 320 \times 9$. Los resultados muestran un

aumento en el rendimiento de las métricas con este método. Se cree que es debido a que la red puede hacer una predicción basada en la información promedio de múltiples imágenes. Para una sola imagen, el valor predicho puede ser o muy alto o muy bajo. En cambio, para imágenes concatenadas, la información combinada podría cancelarse entre sí, dando una mejor predicción promedio. Suponiendo que la red promedie la información, aumentar el número de imágenes podría hacer que la red perdiera la capacidad de respuesta. Por ello emplean 3 *frames* concatenados.

Además, en este artículo se demuestra cualitativamente que las métricas estándar que se emplean para evaluar redes no necesariamente reflejan con precisión el comportamiento de conducción de un sistema. Una matriz de confusión prometedora puede dar como resultado un comportamiento de conducción deficiente, mientras que una matriz con mal aspecto puede dar como resultado un buen comportamiento de conducción.

3.3.2. Redes neuronales recurrentes

Las redes neuronales recurrentes (RNNs) representan una clase de redes neuronales artificiales que utilizan células de memoria para modelar la relación temporal entre los datos de entrada y, por lo tanto, aprender la dinámica subyacente. Con la introducción de las Long Short-Term Memory (LSTM), el modelado de relaciones a largo plazo se hizo posible dentro de RNN.

En múltiples investigaciones sobre conducción autónoma se ha aprovechado la capacidad de estas redes para poder aprovechar la información de imágenes consecutivas. Algunas de estas investigaciones las veremos a continuación.

Un ejemplo de investigación donde se emplean capas LSTM es la propuesta por [15]. En esta investigación se presenta un controlador reactivo basado en aprendizaje profundo que emplea una arquitectura de red simple que requiere pocas imágenes de entrenamiento. A pesar de esta estructura simple, su arquitectura de red, llamada ControlNet, supera a otras redes más complejas en múltiples entornos (entornos interiores estructurados y entornos exteriores no estructurados) utilizando diferentes plataformas robóticas. Es decir, el artículo se centra en el control reactivo, donde el robot debe evitar obstáculos que no están presentes durante la construcción del mapa.

ControlNet extrae imágenes RGB para generar comandos de control: gira a la derecha, gira a la izquierda y recto. La arquitectura de ControlNet consiste en alternar capas convolucionales con capas de *maxpooling* seguidas de capas *fully-connected*. Las capas convolucionales y la de *pooling* extraen información geométrica sobre el medio ambiente, mientras que las capas *fully-connected* actúan como un clasificador general. La capa LSTM permite al robot incorporar información temporal permitiéndole continuar moviéndose en la misma dirección sobre varios *frames*. La estructura de ControlNet (Figura 3.8) es:

- 2D Convolution, 16 filtros de tamaño 10x10
- Max Pooling, filtro de 3x3, stride de 2
- 2D Convolution, 16 filtros de tamaño 5x5
- Max Pooling, filtro de 3x3, stride de 2
- 2D Convolution, 16 filtros de tamaño 5x5
- Max Pooling, filtro de 3x3, stride de 2
- 2D Convolution, 16 filtros de tamaño 5x5
- Max Pooling, filtro de 3x3, stride de 2
- Fully connected, 50 neuronas
- ReLu
- Fully connected, 50 neuronas
- LSTM (5 frames)
- Softmax con 3 salidas

En [30] se propone una Convolutional Long Short-Term Memory Recurrent Neural Networks, conocido como C-LSTM (Figura 3.9), que es entrenable de extremo a extremo,

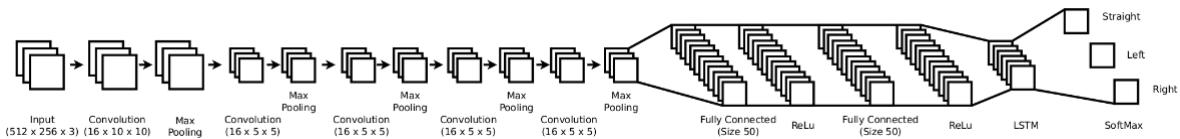


Figura 3.8: Estructura de red ControlNet.

para aprender las dependencias visual y temporal dinámica de la conducción. El sistema investigado está compuesto por una cámara RGB frontal y una red neuronal que consta de una CNN y LSTM que estiman el ángulo del volante en función de la entrada de la cámara. Las imágenes de la cámara se procesan fotograma a fotograma por la CNN. Las características resultantes luego se procesan dentro de la red LSTM para aprender las dependencias temporales. La predicción del ángulo de dirección se calcula a través de la capa de clasificación de salida después de las capas LSTM.

Aplican el concepto de *transfer learning*. La CNN está pre-entrenada en el conjunto de datos Imagenet. Luego, transfieren la red neuronal entrenada a otra específica enfocada en imágenes de conducción. Posteriormente, en la LSTM se procesa una secuencia de vectores de características de longitud fija w de la CNN. A su vez, las capas LSTM aprenden a reconocer las dependencias temporales que conducen a una decisión de dirección Y_t basada en las entradas de X_{t-w} a X_t . Los valores pequeños de t conducen a reacciones más rápidas, pero la red aprende solo las dependencias a corto plazo y la susceptibilidad a los aumentos de *frames* mal clasificados individualmente. Mientras que los valores elevados de t conducen a un comportamiento más suave y, por tanto, predicciones de dirección más estables, pero aumenta las posibilidades de aprender dependencias erróneas a largo plazo.

El concepto de ventana deslizante permite a la red aprender a reconocer diferentes ángulos de dirección desde el mismo *frame* X_i pero en diferentes estados temporales de las capas LSTM. Tanto los pesos de la LSTM como de la CNN se comparten en diferentes pasos dentro de la ventana deslizante y, esto permite un tamaño de ventana arbitrariamente largo.

Plantean la regresión del ángulo de dirección como un problema de clasificación. Esta

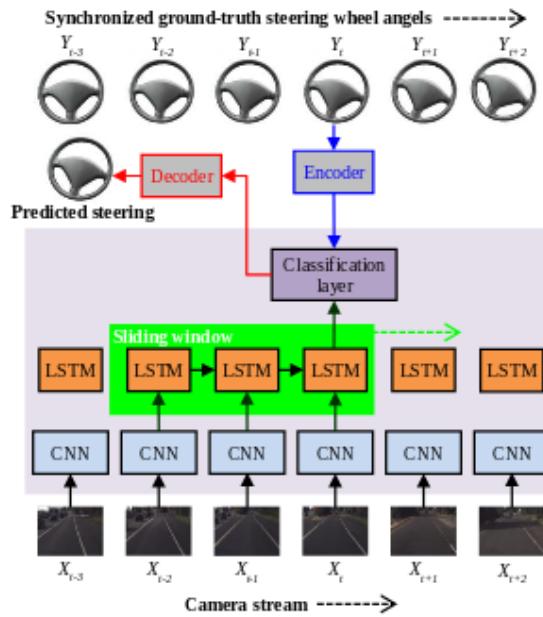


Figura 3.9: Arquitectura C-LSTM.

es la razón por la que el único número que representa el ángulo de dirección Y_t está codificado como un vector de activaciones de las neuronas de la capa de clasificación. Utilizan una capa totalmente conectada con activaciones $tanh$ para la capa de clasificación.

En esta propuesta para el entrenamiento de dominio “específico”, la capa de clasificación de la CNN se reinicializa y se entrena con los datos de carretera de la cámara. El entrenamiento de la capa LSTM se lleva a cabo de manera múltiple, la red aprende las decisiones de dirección que están asociadas con los intervalos de conducción. La capa de clasificación y las capas LSTM emplean una mayor velocidad de aprendizaje porque se inicializan con valores aleatorios. La CNN y la LSTM se entrenan conjuntamente al mismo tiempo.

En [31] se propone un modelo basado en visión que mapea imágenes de entrada en ángulos de dirección usando redes profundas. Se segmenta la red en subredes. Es decir, los *frames* se introducen primero en una red de extracción de características, generando una representación de características de longitud fija que modela el entorno visual y el estado interno de un vehículo. Las características extraídas se envían a una red de predicción de dirección. En la subred de extracción de características emplea una Spatio-Temporal

Convolution (ST-Conv) que cambia las dimensiones temporales y espaciales. Se emplea una capa *fully-connected* tras la ST-Conv para obtener un vector de características de dimensión 128. Además, en la subred de extracción de características se introducen capas LSTM, para lo cual se emplea ConvLSTM. La subred de predicción de dirección propone concatenar acciones de dirección y de estado del vehículo con el vector de características de 128 dimensiones. Para ello se añade 1 paso de recurrencia entre la salida final y las dos capas *concat* justo antes/después de la LSTM. La capa *concat* antes de la LSTM agrega la velocidad, y el par de torsión y ángulo de rueda al vector de 128 dimensiones, formando un vector de 131 dimensiones. La capa *concat* después de LSTM está compuesta por un vector de características 128-d + salida de LSTM 64-d + salida final previa 3d.

En [25] se propone un modelo de atención visual para entrenar una red convolucional de extremo a extremo desde las imágenes hasta el ángulo de giro. El modelo de atención resalta las regiones de imagen que potencialmente influye en la salida de la red, de las cuales algunas son influencias reales y otras espurias. Su modelo predice comandos de ángulo de dirección continuos a partir de píxeles en bruto. El modelo predice el radio de giro inverso \hat{u}_t , pero se relaciona con el comando de ángulo de dirección mediante geometría de Ackermann.

En este método emplean una red neuronal convolucional para extraer un conjunto de vectores de características visuales codificadas, a las que se refieren como una característica convolucional cubo x_t . Cada vector de características puede contener descripciones de objetos de alto nivel que permiten que el modelo de atención preste atención selectiva a ciertas partes de una imagen de entrada al elegir un subconjunto de vectores de características. Utilizan la red PilotNet [24] para aprender un modelo de conducción, pero omiten las capas de *maxpooling* para evitar la pérdida de información de ubicación espacial. Recopilan un cubo x_t de características convolucionales tridimensionales de la última capa empujando la imagen preprocessada a través del modelo, y el cubo de características de salida se emplea como entrada de las capas LSTM. Utilizan una red LSTM que predice el radio de giro inverso y genera ponderaciones de atención en cada paso de tiempo t condicionado al estado oculto anterior y una característica convolucional actual x_t . Asumen una capa oculta condicionada al estado oculto anterior y los vectores de características actuales. El peso de atención para cada ubicación espacial se calcula luego mediante una

función de regresión logística multinomial.

El último paso de este método es un decodificador de grano fino en el que refinan un mapa de atención visual y detectan saliencias visuales locales. Aunque un mapa de atención del decodificador de grano grueso proporciona una probabilidad de importancia sobre un espacio de imagen 2D, el modelo debe determinar regiones específicas que causan un efecto casual en el rendimiento de la predicción. Obtienen una disminución en el rendimiento cuando se oculta una prominencia visual local en una imagen de entrada en bruto. En primer lugar, recopilan un conjunto consecutivo de pesos de atención e ingresan imágenes en bruto para los T pasos de tiempo especificados por el usuario. Luego, crean un mapa de atención, Mt. La red neuronal de 5 capas (basada en PilotNet) emplea una pila de filtros 5x5 y 3x3 sin ninguna capa *pooling*, y por tanto la imagen de dimensiones 80x160 se procesa para producir un cubo de características 10x20x64, conservando su relación de aspecto. Para extraer una prominencia visual local, primero muestran aleatoriamente partículas de 2D con reemplazo sobre una imagen de entrada condicionada en el mapa de atención Mt. También emplean el eje de tiempo como la tercera dimensión para considerar las características temporales de las saliencias visuales, almacenando partículas espacio temporales 3D. Posteriormente, aplican un algoritmo de *clustering* (DBSCAN) para encontrar una prominencia visual local agrupando las partículas 3D en *clusters*. Para los puntos de cada grupo y cada *frame* de tiempo t, calculan el algoritmo *convex hull* para encontrar una región local de cada prominencia visual destacada.

En [29] además de aprovechar la información temporal concatenando *frames* se estudia la inclusión de capas recurrentes. Es decir, modifican su arquitectura para incluir capas LSTM, que permiten capturar información temporal entre entradas consecutivas. Las redes se entrena con un vector de entrada que consiste en la imagen de entrada y una serie de imágenes anteriores, lo que se traduce en una ventana de tiempo. Comparan muchas variaciones de la arquitectura PilotNet [24]: (1) se cambia una o dos capas densas a capas LSTM, (2) se agrega una capa LSTM después de las capas densas, y (3) se cambia la capa de salida a LSTM. Todos los experimentos que realizan con redes LSTM demostraron que la incorporación de capas LSTM no aumentó ni redujo el rendimiento de la red.

En [27] se propone una nueva arquitectura basada en la arquitectura TinyPilotnet

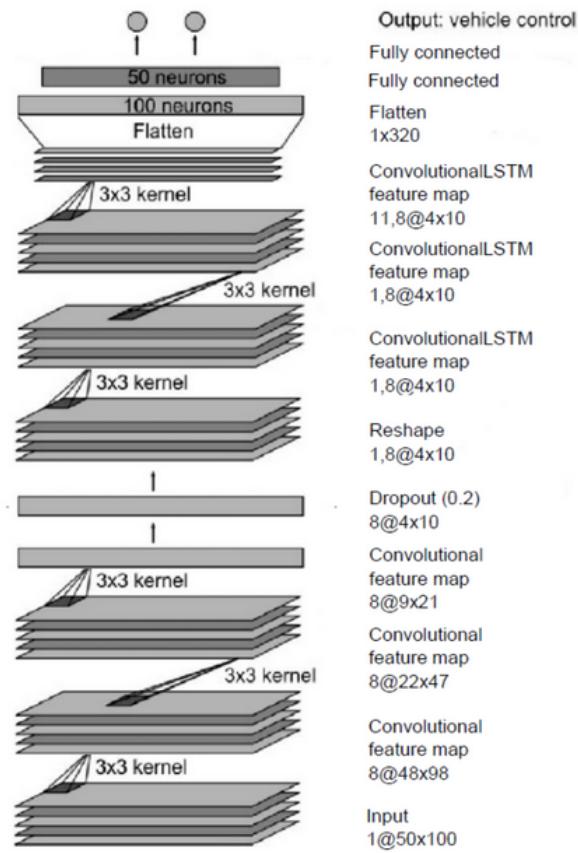


Figura 3.10: Arquitectura DeepestLSTM-TinyPilotnet.

(Figura 3.7) para mejorar el rendimiento de la misma. Esta nueva red (Figura 3.10) está formada principalmente por 3 capas convolucionales de kernel 3x3, combinadas con capas *maxpooling*, seguidas por 3 capas LSTM convolucionales 5x5 y 2 capas *fully-connected*. Las capas LSTM producen un efecto de memoria, por lo que los ángulos de dirección y los valores de aceleración dados por la CNN están influenciados por los anteriores.

3.4. Infraestructura empleada

En esta sección se explican los ingredientes software empleados para desarrollar este proyecto. Se describirá desde el lenguaje empleado hasta diferentes herramientas software que han sido necesarias.

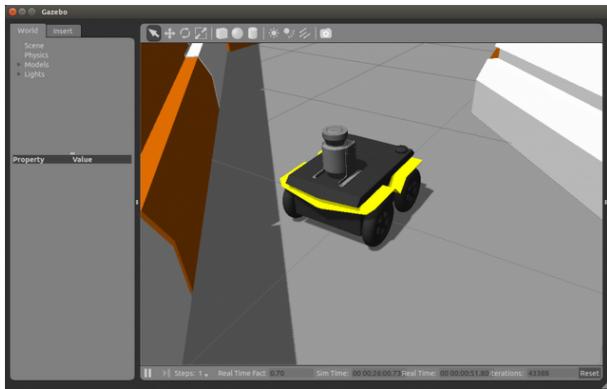


Figura 3.11: Simulador Gazebo.

3.4.1. Simulador Gazebo

Como hemos visto al hablar de simuladores, Gazebo¹ es un programa de código abierto distribuido bajo licencia de Apache 2.0. Se emplea en el desarrollo de aplicaciones robóticas e inteligencia artificial. Es capaz de simular robots, objetos y sensores en entornos complejos de interior y exterior. Tiene gráficas de gran calidad y un robusto motor de físicas (masa del robot, rozamiento, inercia, amortiguamiento, etc.).

En este trabajo se emplea la versión 7.15.0 de Gazebo. Gracias a Gazebo se pueden incluir texturas, luces y sombras en los escenarios, así como simular la física como por ejemplo choques, empujes, gravedad, etc. Además, incluye diversos sensores, como pueden ser cámaras y láseres, los cuales podrán ser incorporados en los robots que empleemos. Todo ello hace que sea una herramienta muy potente y de gran ayuda en robótica.

Los mundos simulados con Gazebo son mundos 3D, que se cargan a partir de ficheros con extensión “.world”. Son ficheros Extensible Markup Language (XML) definidos en el lenguaje Simulation Description Format (SDF). Este lenguaje contiene una descripción completa de todos los elementos que tiene el mundo y los robots, incluyendo:

- Escena: Luz ambiente, propiedades del cielo, sombras, etc.
- Mundo: Representa el mundo como un conjunto de modelos, *plugins* y propiedades físicas.

¹<http://gazebosim.org/>

- Modelo: Articulaciones, objetos de colisión, sensores, etc.
- Físicas: Gravedad, motor físico, paso del tiempo, colisiones, inercias, etc.
- Plugins: Sobre un mundo, modelo o sensor.
- Luz: Los puntos y origen de la luz.

Las etiquetas empleadas en el fichero para representar estos elementos son: Scene, World, Model, Physics, Plugin, y Light.

Los modelos de robots que se emplean en la simulación son creados mediante algún programa de modelado 3D (Blender, Sketchup...). Estos robots simulados necesitan ser dotados de inteligencia para lo cual se emplean los *plugins*. Estos *plugins* pueden dotar al robot de inteligencia u ofrecer la información de sus sensores a aplicaciones externas y recibir de éstas comandos para los actuadores de los robots.

3.4.2. Entorno JdeRobot

JdeRobot² es un *middleware* de software libre para el desarrollo de aplicaciones con robots y visión artificial. Esta plataforma fue creada por el Grupo de Robótica de la Universidad Rey Juan Carlos en 2003 y está licenciada como GPLv3³.

Está desarrollado en C y C++, aunque contiene componentes desarrollados en lenguajes como Python y JavaScript. El entorno que ofrece está basado en componentes, los cuales se ejecutan como procesos. Dichos componentes interoperan entre sí a través del *middleware* de comunicaciones ICE o de ROS messages. Tanto ICE como ROS-messages permiten la interoperación entre los componentes incluso estando desarrollados en diferentes lenguajes.

Es capaz de llevar a cabo diferentes tareas en tiempo real de forma sencilla. Cada componente *driver* está asociado a un dispositivo hardware del robot, un sensor o actuador e incluye funciones para poder emplearlo. Esto simplifica el acceso a los diferentes

²http://jderobot.org/Main_Page

³<https://www.gnu.org/licenses/quick-guide-gplv3.html>

componentes hardware, ya que con una simple función se puede acceder a ellos.

Las aplicaciones constan de uno o varios componentes. Los que interactúan directamente con los sensores y actuadores del robot se llaman *drivers*, que son los encargados de controlar que los robots reciben órdenes a través de interfaces ICE o ROS messages. Otros llevan en su código las funciones perceptivas, procesamiento de señales o la lógica de control e inteligencia del robot. En la siguiente imagen se puede ver un ejemplo de esta comunicación con un AR Drone empleando interfaces ICE. La misma lógica de comportamiento se puede conectar al *driver* del drone real o al *driver* del drone simulado, basta con cambiar la configuración.

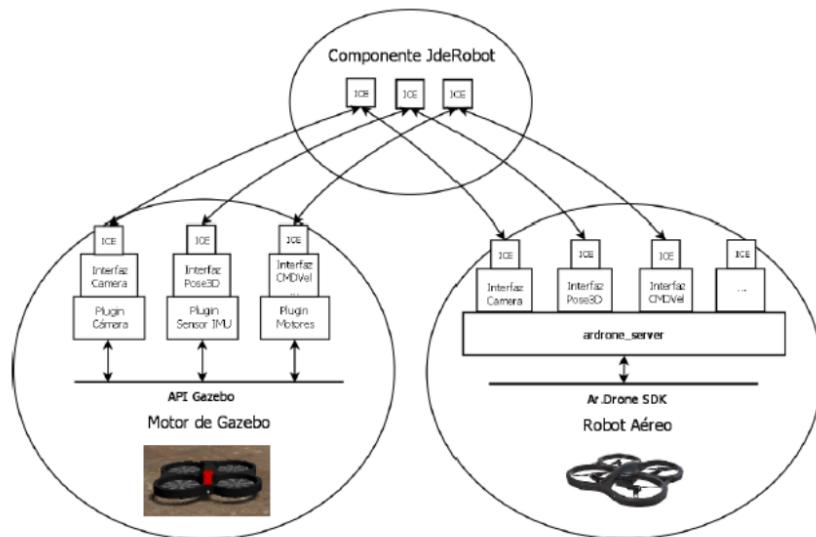


Figura 3.12: Ejemplo de componentes JdeRobot

Esta plataforma soporta gran variedad de dispositivos como el cuadricóptero AR Drone de Parrot, el robot Pioneer de MobileRobotics Inc., el robot Kobuki de Yujin Robot, el robot Pibot de JdeRobot-kids⁴, el robot Mbot de JdeRobot-kids, cámaras firewire, USB e IP, los escáneres laser LMS de SICK y URG de Hokuyo, el simulador Gazebo, sensores de profundidad como Kinect y otros dispositivos X10 de domótica. A parte de todo esto, tiene soporte para software externo como OpenCV, OpenGL, XForms, GTK, Player y GSL.

⁴<https://jderobot.org/PyBoKids>

En el desarrollo del proyecto de este TFM se empleará la versión 5.6.7 de JdeRobot, ya que es la última versión estable.

3.4.3. Python

Python⁵ es un lenguaje de programación fácil de aprender y de alto nivel. Su creador fue Guido van Rossum, un investigador holandés que trabajaba en el centro de investigación CWI (Centrum Wiskunde & Informatica). La primera versión surgió en 1991 pero no fue publicada hasta tres años después. Guido dio el nombre de Python en honor a la serie de televisión *Monty Python's Flying Circus*.

Python incluye orientación a objetos, manejo de excepciones, listas, diccionarios, etc. A pesar de todo lo que soporta, se creó con el objetivo de que fuera un lenguaje sencillo de entender y manejar, sin perder las funcionalidades que pueden ofrecer lenguajes complejos tales como C.

Actualmente Python es un lenguaje de código abierto administrado por Python Software Foundation. Incluye módulos que permiten la entrada y salida de ficheros, *sockets*, llamadas al sistema e incluso interfaces gráficas como Qt. Además, permite dividir el programa en módulos reutilizables y no es necesario compilarlo, pues es interpretado. Es uno de los ejes de Robotics-Academy.

La última versión ofrecida por Python Software Foundation es la 3.7.3 , pero en nuestro caso se empleará la 2.7.12 por compatibilidad con JdeRobot 5.6.7, que a su vez sigue en esa versión de Python para ser compatible con ROS Kinetic. El código en el que están escritos los componentes académicos y las soluciones es Python.

3.4.4. Biblioteca OpenCV

OpenCV⁶ es una librería de código abierto desarrollada inicialmente por Intel y publicada bajo licencia de BSD. Esta librería implementa gran variedad de herramientas para la interpretación de la imagen. Sus siglas provienen de los términos anglosajones

⁵<https://www.python.org/>

⁶<http://opencv.org/>

CAPÍTULO 3. ESTADO DEL ARTE

“Open Source Computer Vision Library”, y está orientada a aplicaciones de visión por computador en tiempo real.

Esta librería puede ser usada en MacOS, Windows, Android y Linux, y existen versiones para C#, Python y Java, a pesar de que originalmente era una librería en C/C++. Además, hay interfaces en desarrollo para Ruby, Matlab y otros lenguajes.

OpenCV principalmente implementa algoritmos para las técnicas de calibración, detección de rasgos, para el rastreo, análisis de la forma, análisis del movimiento, reconstrucción 3D, segmentación de objetos y reconocimiento. Los algoritmos se basan en estructuras de datos flexibles acopladas con estructuras IPL (Intel Image Processing Library), aprovechándose de la arquitectura de Intel en la optimización de más de la mitad de las funciones.

Fue diseñado para tener una alta eficiencia computacional. Está escrito en C y puede aprovechar las ventajas de los procesadores multinúcleo. La biblioteca de OpenCV contiene más de 500 funciones que abarcan muchas áreas de la visión artificial. También tiene una librería de aprendizaje automático (MLL, Machine Learning Library) destinada al reconocimiento y agrupación de patrones estadísticos.

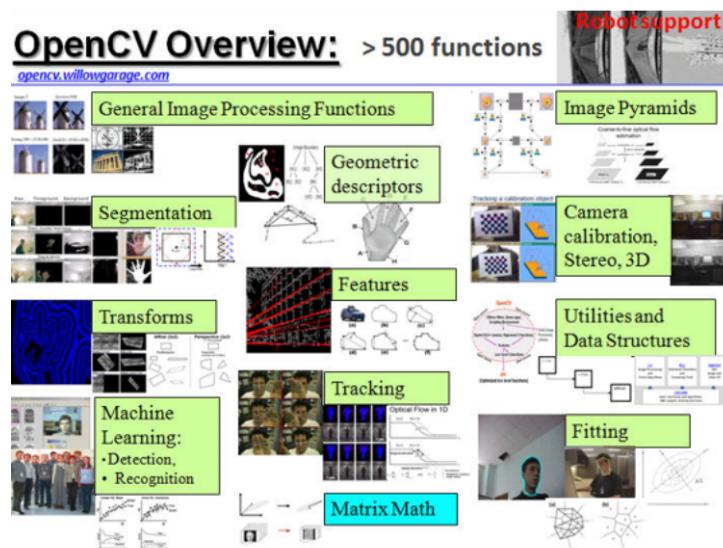


Figura 3.13: Funciones de OpenCV

OpenCV está compuesto por numerosas librerías con las cuales podemos manejar estructuras de datos, detectar bordes y esquinas, escalar o rotar imágenes, modificar el espacio de color de una imagen, realizar emparejamiento, detectar líneas y círculos, tratar objetos en 3D, crear ventanas y asociar eventos a dichas ventanas, etc. Incorpora funciones básicas para modelar el fondo, sustraer dicho fondo, generar imágenes de movimiento MHI (Motion History Images), etc. Además, incluye funciones para determinar dónde hubo movimiento y en qué dirección.

Desde su aparición OpenCV ha sido usado en numerosas aplicaciones. Hay una gran cantidad de empresas y centros de investigación que emplean estas técnicas como IBM, Microsoft, Intel, SONY, Siemens, Google, Stanford, MIT, CMU, Cambridge e INRIA.

En este trabajo se ha empleado la versión 3.3.1 de OpenCV en Python. Esta librería se empleará para realizar todo lo relacionado con el tratamiento de imágenes. Con ella se extraerán datos que puedan emplearse a la hora de tomar decisiones para que el coche funcione correctamente.

3.4.5. PyQt

PyQt [32] [33] es un conjunto de enlaces Python para el conjunto de herramientas Qt, las cuales se emplean para el desarrollo de interfaces gráficas. Fue desarrollado por Riverbank Computing Ltd y es soportado por Windows, Linux, Mac OS/X, iOS y Android.

Qt es un entorno multiplataforma orientado a objetos desarrollado en C++ que permite desarrollar interfaces gráficas e incluye *sockets*, hilos, Unicode, bases de datos SQL, etc. PyQt combina todas las ventajas de Qt y Python, pues permite emplear todas las funcionalidades ofrecidas por Qt con un lenguaje de programación tan sencillo como Python.

En este proyecto se ha empleado la versión 5 (en concreto la versión 5.5.1) de PyQt. PyQt5 es un conjunto de enlaces Python para Qt5, disponible en Python 2.x y 3.x. Tiene más de 620 clases y 6000 funciones y métodos. PyQt5 dispone de una licencia dual, es decir, los desarrolladores pueden elegir entre una licencia GPL (General Public Licence) o una licencia comercial.

La interfaz gráfica del componente académico creado en este proyecto está escrita usando PyQt. Las clases de PyQt5 se dividen en ciertos módulos, tales como QtCore, QtGui, QtWidgets, QDom, QSql, etc. En este proyecto se ha hecho uso de los siguientes módulos:

- QtCore: contiene las funcionalidades principales que no tienen que ver con la GUI. Este módulo se emplea para trabajar con archivos, diferentes tipos de datos, hilos, procesos, url, etc.
- QtGui: contiene clases para el desarrollo de ventanas, gráficos 2D, imágenes y texto.
- QtWidgets: dispone de clases que proporcionan un conjunto de elementos de interfaz de usuario para crear GUIs clásicas de escritorio.
- QtSvg: proporciona clases para mostrar el contenido de archivos Scalable Vector Graphics (SVG). SVG es un lenguaje para describir gráficos bidimensionales y aplicaciones gráficas en XML.

3.4.6. Keras framework

Keras⁷ es un *framework* de alto nivel para redes neuronales, escrito en Python y capaz de correr sobre los *frameworks* TensorFlow, CNTK, o Theano. Fue desarrollado para facilitar la experimentación rápida.

Keras fue desarrollado con el fin de que la implementación de modelos de aprendizaje profundo fuera lo más fácil y rápido posible para la investigación y el desarrollo.

Este *framework* se ejecuta en Python 2.7-3.6, y es posible ejecutarlo tanto en CPU como en GPU. Keras se liberó bajo la licencia permisiva del MIT [34]. Keras fue desarrollado y mantenido por François Chollet, un ingeniero de Google que utiliza cuatro principios:

- Facilidad de uso: Keras es una API diseñada basándose en la experiencia del usuario, es decir, ofrece un API consistente y simple, proporciona comentarios claros y procesables en caso de error del usuario.

⁷<https://keras.io/>

- Modularidad: Un modelo se entiende como una secuencia o un gráfico de módulos independientes, totalmente configurables, que se pueden conectar con la menor cantidad de restricciones posible. En concreto, las capas neuronales, las funciones de coste, los optimizadores, los esquemas de inicialización, las funciones de activación y los esquemas de regularización son módulos independientes que se pueden combinar para crear nuevos modelos.
- Fácil extensibilidad: Los nuevos módulos son fáciles de agregar, y los módulos existentes proporcionan amplios ejemplos. La posibilidad de crear fácilmente nuevos módulos permite una extensibilidad total, lo que hace que Keras sea adecuado para la investigación avanzada.
- Trabajo con Python: No hay archivos de configuración de modelos separados en un formato declarativo, sino que los modelos se describen en el código de Python, facilitando la depuración de código y permitiendo la extensibilidad.

La versión principal utilizada en este proyecto es Keras 2.2.4, y se ha ejecutado sobre TensorFlow. Keras ha sido empleado para entrenar e implementar diferentes arquitecturas de redes neuronales.

En las próximas subsecciones, se analizan los elementos principales que forman una red neuronal convolucional y una red neuronal recurrente (LSTM) construida con Keras, comenzando con el objeto modelo.

3.4.6.1. Modelos

En Keras cada red neuronal se define como un modelo, es una forma de organizar las capas. La clase de modelo más simple es el modelo *Sequential*, que es una pila lineal de capas. Es posible construir arquitecturas más complejas, aunque se debe utilizar la API funcional de Keras, que permite crear gráficos de capas arbitrarios.

Los modelos *Sequential* tienen diferentes métodos, y los algunos son imprescindibles para el proceso de aprendizaje, como son:

- **.compile()**: Configura el modelo para entrenamiento. Los principales argumentos son los siguientes:

- *optimizer*: Nombre del optimizador que actualizará los valores de los pesos durante el entrenamiento para minimizar la función de pérdida.
 - *loss*:
 - *metrics*
- **.fit()**:
 - **.predict()**: Genera predicciones de salida para las muestras de entrada.
 - **.evaluate()**: Devuelve el valor de *loss* y los valores de *metrics* para el modelo en *test*.
 - **.save()**: Guarda un modelo en un solo archivo Hierarchical Data Format version 5 (HDF5), que contendrá la arquitectura del modelo, los pesos del modelo, la configuración de entrenamiento, y el estado del optimizador (permite reanudar el entrenamiento por donde se quedó).
 - **.load_model()**: Carga un modelo desde un archivo HDF5.

3.4.6.2. Capas

3.4.6.3. *Callbacks*

3.4.7. Formato de archivo HDF5

Hierarchical Data Format version 5 (HDF5) [35] [36] es una librería de propósito general y al mismo tiempo un formato de ficheros para el almacenamiento de datos científicos. HDF5 fue creado con el fin de facilitar el trabajo a los ingenieros y científicos que trabajan en entornos con altas prestaciones y con un uso masivo de datos. Keras emplea el formato de archivo HDF5 para guardar modelos y leer conjuntos de datos. La tecnología HDF5 incluye:

- Un modelo de datos versátil que puede representar objetos de datos complejos y una gran variedad de metadatos.
- Un formato de archivo completamente portable sin límite en el número o tamaño de los objetos de datos de una colección.

- Una biblioteca software que se ejecuta en diversas plataformas computacionales como ordenadores portátiles o sistemas masivamente paralelos. Además, implementa una API de alto nivel con interfaces C, C++, Fortran 90 y Java.
- Un gran conjunto de funciones de rendimiento que permiten optimizar el tiempo de acceso y el espacio de almacenamiento.
- Herramientas y aplicaciones para manejar, manipular, visualizar y analizar datos.
- El modelo de datos HDF5, el formato de archivo, la biblioteca y las herramientas son de código libre.

En este trabajo se han empleado los archivos HDF5 para guardar los modelos de las diferentes redes. Para tratar con archivos HDF5 se emplea la biblioteca h5py⁸ para Python.

⁸www.h5py.org

Capítulo 4

Infraestructura desarrollada

4.1. Circuitos

4.2. Piloto manual

4.3. Creación del dataset

4.4. Componente académico

Capítulo 5

Redes de clasificación

Capítulo 6

Redes de regresión

Capítulo 7

Conclusiones

Bibliografía

- [1] Ian Goodfellow, Yoshua Bengio, and Aaron Courville. *Deep Learning*. MIT Press, 2016. <http://www.deeplearningbook.org>.
- [2] Anyu. "RNA – Redes Neuronales Artificiales", *Bitácoras de un Ingeniero*. <http://andrealezcano.blogspot.com.es/2011/04/rna-redes-neuronales-artificiales.html>, 2011. [Accedido 29 de Mayo de 2019].
- [3] MIT Computer Science & Artificial Intelligence Lab. Using AI to predict breast cancer and personalize care. <https://www.csail.mit.edu/news/using-ai-predict-breast-cancer-and-personalize-care>, 2019. [Accedido 30 de Mayo de 2019].
- [4] Janosch Delcker. The man who invented the self-driving car (in 1986). <https://www.politico.eu/article/delf-driving-car-born-1986-ernst-dickmanns-mercedes/>, 2018. [Accedido 30 de Mayo de 2019].
- [5] Dean A. Pomerleau. Alvinn: An autonomous land vehicle in a neural network. In D. S. Touretzky, editor, *Advances in Neural Information Processing Systems 1*, pages 305–313. Morgan-Kaufmann, 1989.
- [6] Automated driving levels of driving automation are defined in new SAE International Standard J3016. https://www.smmmt.co.uk/wp-content/uploads/sites/2/automated_driving.pdf, 2014. [Accedido 3 de Junio de 2019].
- [7] S.Kom M.Eng. Dewi Suryani. Convolutional Neural Network, *Binus University - School of Computer Science*. <http://soc.s.binus.ac.id/2017/02/27/convolutional-neural-network/>, 2017. [Accedido 31 de Mayo de 2019].
- [8] Sepp Hochreiter and Jürgen Schmidhuber. Long short-term memory. *Neural Computation*, 9:1735–1780, 1997.

CAPÍTULO 7. CONCLUSIONES

- [9] Galo Fariño R. Modelo Espiral de un proyecto de desarrollo de software, *Administración y Evaluación de Proyectos*. <http://www.ojovisual.net/galofarino/modeloespiral.pdf>, 2011. [Accedido 31 de Mayo de 2019].
- [10] Modelo Espiral. <http://modeloespiral.blogspot.com.es/>, 2009. [Accedido 31 de Mayo de 2019].
- [11] Herramientas software. https://moodle2.unid.edu.mx/dts_cursos_mdl/licIEL/HS/S04/HS04_Lectura.pdf. [Accedido 31 de Mayo de 2019].
- [12] Eder Santana and George Hotz. Learning a driving simulator. *CoRR*, abs/1608.01230, 2016.
- [13] Self Driving Car Engineer. <https://eu.udacity.com/course/self-driving-car-engineer-nanodegree--nd013>, 2017. [Accedido 30 de Abril de 2019].
- [14] Mariusz Bojarski, Philip Yeres, Anna Choromanska, Krzysztof Choromanski, Bernhard Firner, Lawrence D. Jackel, and Urs Muller. Explaining how a deep neural network trained with end-to-end learning steers a car. *CoRR*, abs/1704.07911, 2017.
- [15] Keith Sullivan and Wallace Lawson. Reactive ground vehicle control via deep networks. 2017.
- [16] Udacity's Datasets. <https://github.com/udacity/self-driving-car/tree/master/datasets>, 2016. [Accedido 30 de Abril de 2019].
- [17] Zhengyuan Yang, Yixuan Zhang, Jerry Yu, Junjie Cai, and Jiebo Luo. End-to-end multi-modal multi-task vehicle control for self-driving cars with visual perceptions. *2018 24th International Conference on Pattern Recognition (ICPR)*, pages 2289–2294, 2018.
- [18] Alexey Dosovitskiy, Germán Ros, Felipe Codevilla, Antonio López, and Vladlen Koltun. Carla: An open urban driving simulator. In *CoRL*, 2017.
- [19] CARLA: Open-source simulator for autonomous driving research. <http://carla.org/>, 2017. [Accedido 30 de Abril de 2019].
- [20] Gazebo. <http://gazebosim.org/>, 2011. [Accedido 30 de Abril de 2019].

- [21] Udacity’s Self-Driving Car Simulator. <https://github.com/udacity/self-driving-car-sim/>, 2017. [Accedido 30 de Abril de 2019].
- [22] Deepdrive: self-driving AI. <https://deepdrive.io/>, 2017. [Accedido 30 de Abril de 2019].
- [23] Urs Muller, Jan Ben, Eric Cosatto, Beat Flepp, and Yann L. Cun. Off-road obstacle avoidance through end-to-end learning. In Y. Weiss, B. Schölkopf, and J. C. Platt, editors, *Advances in Neural Information Processing Systems 18*, pages 739–746. MIT Press, 2006.
- [24] Mariusz Bojarski, Davide Del Testa, Daniel Dworakowski, Bernhard Firner, Beat Flepp, Prasoon Goyal, Lawrence D. Jackel, Mathew Monfort, Urs Muller, Jiakai Zhang, Xin Zhang, Jake Zhao, and Karol Zieba. End to end learning for self-driving cars. *CoRR*, abs/1604.07316, 2016.
- [25] Jinkyu Kim and John F. Canny. Interpretable learning for self-driving cars by visualizing causal attention. *2017 IEEE International Conference on Computer Vision (ICCV)*, pages 2961–2969, 2017.
- [26] Mariusz Bojarski, Anna Choromanska, Krzysztof Choromanski, Bernhard Firner, Larry J. Ackel, Urs Muller, Philip Yeres, and Karol Zieba. Visualbackprop: Efficient visualization of cnns for autonomous driving. *2018 IEEE International Conference on Robotics and Automation (ICRA)*, pages 1–8, 2018.
- [27] Javier del Egio, Luis Bergasa, Eduardo Romera, Carlos Gómez Huélamo, Javier Araluce, and Rafael Barea. *Self-driving a Car in Simulation Through a CNN: Proceedings of the 19th International Workshop of Physical Agents (WAF 2018), November 22-23, 2018, Madrid, Spain*, pages 31–43. 01 2019.
- [28] Ana I. Maqueda, Antonio Loquercio, Guillermo Gallego, Narciso García, and Davide Scaramuzza. Event-based vision meets deep learning on steering prediction for self-driving cars. *2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 5419–5427, 2018.
- [29] Jonas Heylen, Seppe Iven, Bert De Brabandere, M. Oramas JoséOramas, Luc Van Gool, and Tinne Tuytelaars. From pixels to actions: Learning to drive a car with

- deep neural networks. *2018 IEEE Winter Conference on Applications of Computer Vision (WACV)*, pages 606–615, 2018.
- [30] Hesham M. Eraqi, Mohamed N. Moustafa, and Jens Honer. End-to-end deep learning for steering autonomous vehicles considering temporal dependencies. *CoRR*, abs/1710.03804, 2017.
- [31] Lu Chi and Yadong Mu. Deep steering: Learning end-to-end driving model from spatial and temporal visual cues. *CoRR*, abs/1708.03798, 2017.
- [32] Jan Bodnar. Introduction to PyQt5. <http://zetcode.com/gui/pyqt5/introduction/>, 2017. [Accedido 10 de Junio de 2019].
- [33] What is PyQt?, *Riverbank Computing Limited*. <https://riverbankcomputing.com/software/pyqt/intro>, 2016. [Accedido 9 de Junio de 2019].
- [34] Keras team. Licencia de Keras, *Github*. <https://github.com/keras-team/keras/blob/master/LICENSE>, 2019. [Accedido 12 de Junio de 2019].
- [35] The HDF5 Library & File Format. <https://www.hdfgroup.org/solutions/hdf5/>, 2019. [Accedido 12 de Junio de 2019].
- [36] What is HDF5? <https://support.hdfgroup.org/HDF5/whatishdf5.html>, 2019. [Accedido 12 de Junio de 2019].
- [37] Ibáñez. De 0 a 5: cuáles son los diferentes niveles de conducción autónoma, a fondo, *xataka*. <https://www.xataka.com/automovil/de-0-a-5-cuales-son-los-diferentes-niveles-de-conduccion-autonomia>, 2017. [Accedido 29 de Mayo de 2019].
- [38] Diccionario de Internet y Tecnologías de la Información y la Comunicación. Paradoja de Moravec : que es, definición y significado, descargar videos y fotos, *Internet y Tecnologías de la Información y la Comunicación*. <https://www.paraisodigital.org/internet/11-paradoja-de-moravec-que-es-definicion-y-significado-descargar-videos-y-fotos.html>, 2018. [Accedido 29 de Mayo de 2019].

CAPÍTULO 7. CONCLUSIONES

- [39] Betzaida Zambrano and Jorge Hernández. Técnicas y campos de la Inteligencia Artificial. <https://es.slideshare.net/beshi/tecnicas-y-camposdelaibzjh>, 2013. [Accedido 29 de Mayo de 2019].
- [40] Indra. Una imagen vale más que mil palabras: Visión Artificial. https://www.minsait.com/sites/default/files/newsroom_documents/unaimagenvalemasquemilpalabras.pdf. [Accedido 30 de Mayo de 2019].
- [41] Pedro Javier Oscar Sergio Alejandro, Vicente and Carlos. Introducción al Diseño de Micro Robots Móviles2009/10: Sistemas De Visión Artificial. https://www.google.com/url?sa=t&rct=j&q=&esrc=s&source=web&cd=6&cad=rja&uact=8&ved=2ahUKEwjm3_TF9tziAhUuxYUKHdmADZQQFjAFegQIAxAC&url=http%3A%2F%2Fwww.roboticaeducativa.org%2Fmod%2Fresource%2Fview.php%3Fid%3D2051&usg=A0vVaw1WxJXLKEuuu7WpK08VivRb, 2010. [Accedido 30 de Mayo de 2019].
- [42] AbdelmalikMoujahid Pedro Larra naga, I nakiInza. Tema8. RedesNeuronale. <http://www.sc.ehu.es/ccwbayes/docencia/mmcc/docs/t8neuronales.pdf>. [Accedido 31 de Mayo de 2019].
- [43] Skymind. A Beginner's Guide to Neural Networks and Deep Learning, *A.I. Wiki*. <https://skymind.ai/wiki/neural-network>. [Accedido 31 de Mayo de 2019].
- [44] Antonio Blanco Emilio Soria. Redes neuronales artificiales. https://www.acta.es/medios/articulos/informatica_y_computacion/019023.pdf. [Accedido 31 de Mayo de 2019].
- [45] Fernando Sancho Caparrini. Redes Neuronales: una visión superficial. <http://www.cs.us.es/~fsancho/?e=72>. [Accedido 31 de Mayo de 2019].
- [46] Damián Jorge Matich. Redes Neuronales: Conceptos Básicos y Aplicaciones. https://www.frro.utn.edu.ar/repositorio/catedras/quimica/5_anio/orientadora1/monograias/matich-redesneuronales.pdf, 2001. [Accedido 31 de Mayo de 2019].
- [47] Mayank Mishra. Convolutional Neural Networks, Explained. <https://www.datascience.com/blog/convolutional-neural-network>, 2019. [Accedido 31 de Mayo de 2019].

- [48] Raul E. Lopez Briega. Redes neuronales convolucionales con TensorFlow. <https://relopezbriega.github.io/blog/2016/08/02/redes-neuronales-convolucionales-con-tensorflow/>, 2016. [Accedido 31 de Mayo de 2019].
- [49] Omar Emilio Contreras Zaragoza. *Desarrollo de una red neuronal convolucional para el procesamiento de imágenes placentarias*. PhD thesis, Universidad Nacional Autónoma de México, 2018. [Accedido 1 de Junio de 2019].
- [50] Pablo Pastor Martín. *Usando Redes Neuronales Convolucionales Para Convertir Características Visuales en Estímulos Sonoros*. PhD thesis, Universidad de La Laguna, 2018. [Accedido 1 de Junio de 2019].
- [51] John Marturet Rodrigo. *Evaluación de redes neuronales convolucionales para la clasificación de imágenes histológicas de cáncer colorrectal mediante transferencia de aprendizaje*. PhD thesis, Universitat Oberta de Catalunya, 2018. [Accedido 1 de Junio de 2019].
- [52] Jaime Durán Suárez. *Redes Neuronales Convolucionales en R*. PhD thesis, Escuela Técnica Superior de Ingeniería, Universidad de Sevilla, 2017. [Accedido 1 de Junio de 2019].
- [53] José Francisco Núñez Castro. *Aprendizaje automático en fusión nuclear con Deep Learning*. PhD thesis, Pontifica Universidad Católica de Valparaíso, 2017. [Accedido 1 de Junio de 2019].
- [54] Oinkina and Hakyll. Understanding LSTM Networks. <https://colah.github.io/posts/2015-08-Understanding-LSTMs/>, 2015. [Accedido 1 de Junio de 2019].
- [55] Secretaría de Estado de Educación y Formación Profesional. Visión Artificial: Aplicación práctica de la visión artificial en el control de procesos industriales. http://visionartificial.fpcat.cat/wp-content/uploads/UD_1_didac_Conceptos_previos.pdf, 2012. [Accedido 29 de Mayo de 2019].
- [56] Philipp Kandal. From Zero to Waymo: The Story of Google's Driverless Car. <https://kandal.com/essays/from-zero-to-waymo-the-story-of-googles-driverless-car>, 2017. [Accedido 30 de Mayo de 2019].

CAPÍTULO 7. CONCLUSIONES

- [57] David Villarreal. BMW y Mercedes-Benz unen fuerzas para desarrollar coches autónomos, Diariomotor. <https://www.diariomotor.com/noticia/bmw-mercedes-unen-fuerzas-coche-autonomo/>, 2019. [Accedido 30 de Mayo de 2019].
- [58] Gustav von Zitzewitz. Survey of neural networks in autonomous driving. 07 2017.
- [59] Yunpeng Pan, Ching-An Cheng, Kamil Saigol, Keuntaek Lee, Xinyan Yan, Evangelos A. Theodorou, and Byron Boots. Agile autonomous driving using end-to-end deep imitation learning. In *Robotics: Science and Systems*, 2018.
- [60] Lucas Martín. Gazebo, simulador de robótica, *Automatismos Mar del Plata*. <http://www.automatismos-mdq.com.ar/blog/2017/01/gazebo-simulador-de-robotica.html>, 2017. [Accedido 30 de Abril de 2019].
- [61] Gazebo Simulator: simular un robot nunca fue tan fácil, *Robologs*. <https://robologs.net/2016/06/25/gazebo-simulator-simular-un-robot-nunca-fue-tan-facil/>, 2016. [Accedido 30 de Abril de 2019].
- [62] Follow line: JdeRobot RoboticsAcademy. https://github.com/JdeRobot/RoboticsAcademy/tree/master/exercises/follow_line, 2017. [Accedido 30 de Septiembre de 2018].
- [63] Javier Antón Alonso and Xuebo Zhu Chen. *Estudio y simulación de un vehículo autopilotado en Unity 5 haciendo uso de algoritmos de aprendizaje automático*. PhD thesis, Universidad Complutense Madrid, 2018. [Accedido 2 de Junio de 2019].
- [64] Joshué Manuel Pérez Rastelli. *Agentes de control de vehículos autónomos en entornos urbanos y autovías*. PhD thesis, Universidad Complutense Madrid, 2012. [Accedido 2 de Junio de 2019].
- [65] Chenyi Chen, Ari Seff, Alain L. Kornhauser, and Jianxiong Xiao. Deepdriving: Learning affordance for direct perception in autonomous driving. *2015 IEEE International Conference on Computer Vision (ICCV)*, pages 2722–2730, 2015.
- [66] Antonio Paladini. *End-to-end Models for Lane Centering in Autonomous Driving*. PhD thesis, Politecnico di Milano, 2018. [Accedido 6 de Junio de 2019].

- [67] Simon Kardell and Mattias Kuosku. *Autonomous vehicle control via deep reinforcement learning*. PhD thesis, Chalmers University of Technology, 2017. [Accedido 7 de Junio de 2019].
- [68] David Ungurean. *DeepRCar: An Autonomous Car Model*. PhD thesis, Faculty of Information Technology CTU in Prague, 2018. [Accedido 7 de Junio de 2019].
- [69] Yuke Zhu, Roozbeh Mottaghi, Eric Kolve, Joseph J. Lim, Abhinav Gupta, Li Fei-Fei, and Ali Farhadi. Target-driven visual navigation in indoor scenes using deep reinforcement learning. *2017 IEEE International Conference on Robotics and Automation (ICRA)*, pages 3357–3364, 2017.
- [70] Jeff Donahue, Lisa Anne Hendricks, Sergio Guadarrama, Marcus Rohrbach, Subhashini Venugopalan, Kate Saenko, and Trevor Darrell. Long-term recurrent convolutional networks for visual recognition and description. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 39:677–691, 2015.
- [71] Tharindu Fernando, Simon Denman, Sridha Sridharan, and Clinton Fookes. Going deeper: Autonomous steering with neural memory networks. *2017 IEEE International Conference on Computer Vision Workshops (ICCVW)*, pages 214–221, 2017.
- [72] Arthur Emidio T. Ferreira, Ana Paula Goncalves Soares de Almeida, and Flavio de Barros Vidal. Autonomous vehicle steering wheel estimation from a video using multichannel convolutional neural networks. In *ICINCO*, 2018.
- [73] David Gerónimo Gómez. *Visión Artificial aplicada a vehículos inteligentes*. PhD thesis, Universitat Autònoma de Barcelona, 2004. [Accedido 1 de Junio de 2019].
- [74] Keras documentation. Keras: The Python Deep Learning library. <https://keras.io/>. [Accedido 10 de Junio de 2019].
- [75] Jesús Utrera Burgal. Deep Learning básico con Keras (Parte 1). <https://enmilocalfunciona.io/deep-learning-basico-con-keras-parte-1/>. [Accedido 10 de Junio de 2019].
- [76] Jason Brownlee. Introduction to Python Deep Learning with Keras. <https://machinelearningmastery.com/introduction-to-python-deep-learning-with-keras/>

- introduction-python-deep-learning-library-keras/l, 2016. [Accedido 12 de Junio de 2019].
- [77] Carlos Santana. Historia de Python. <https://www.codejobs.biz/es/blog/2013/03/03/historia-de-python>, 2013. [Accedido 11 de Junio de 2019].
- [78] Python Software Foundation. Tutorial de Python. <http://docs.python.org.ar/tutorial/3/real-index.html>, 2017. [Accedido 11 de Junio de 2019].
- [79] Python, *EcuRed*. <https://www.ecured.cu/Python>, 2017. [Accedido 11 de Junio de 2019].
- [80] J.M Cañas. *Programación de robots con la plataforma Jderobot*. PhD thesis, Universidad de Málaga, 2009. [Accedido 12 de Junio de 2019].
- [81] Julio Manuel Vega. *Navegación y autolocalización de un robot guía de visitantes*. PhD thesis, Universidad Rey Juan Carlos. Ingeniería Informática, 2009. [Accedido 12 de Junio de 2019].
- [82] Página Oficial de OpenCV. <http://opencv.org/>, 2019. [Accedido 12 de Junio de 2019].
- [83] V. M. Arévalo, J. González, and G. Ambrosio. *La Librería de Visión Artificial OpenCV, Aplicación a la Docencia e Investigación*. PhD thesis, Dpto. De Ingeniería de Sistemas y Automática, Universidad de Málaga, 2004. [Accedido 12 de Junio de 2019].